

به نام خدا

گزارش پروژه:

پیش بینی دمای روز آینده تهران

با یادگیری ماشین و مهندسی ویژگی های هواشناسی

ایستگاه هواشناسی مهرآباد، تهران (۲۰۲۰ تا ۲۰۲۵)

نام دانشجو: امیرحسین داورزنی

استاد راهنما: سرکار خانم دکتر کیمیا پیوندی

شهریور ۱۴۰۵

فهرست مطالب

چکیده	۴
فصل اول: مرور ادبیات و پیشینه تحقیق	۵
۱-۱- مقدمه‌ای بر مسئله پیش‌بینی دما	۵
۱-۲- روش‌های آماری کلاسیک	۶
۱-۳- مدل‌های عددی پیش‌بینی جو (NWP)	۶
۱-۴- شبکه‌های عصبی و یادگیری عمیق	۷
۱-۵- مدل‌های مبتنی بر درخت و تقویت گرادیان	۸
۱-۶- مهندسی ویژگی در سری‌های زمانی هواشناسی	۸
۱-۷- داده‌های بازتحلیل جو و رابط‌های برنامه‌نویسی هواشناسی	۹
۱-۸- مسئله ناشی داده در ارزیابی مدل‌های سری زمانی	۹
۱-۹- مطالعات مرتبط در ایران و منطقه تهران	۱۰
۱-۱۰- جمع‌بندی مرور ادبیات و شکاف تحقیقاتی	۱۰
فصل دوم: روش پیشنهادی	۱۲
۲-۱- بیان رسمی مسئله	۱۲
۲-۲- معماری کلی خط لوله پیشنهادی	۱۲
۲-۳- داده‌ها	۱۳
۲-۴- پیش‌پردازش داده	۱۵
۲-۵- مهندسی ویژگی	۱۵
۲-۶- اصلاحات روش شناختی انجام‌شده در فرایند مهندسی ویژگی	۱۸
۲-۷- مدل‌های مورد مقایسه	۱۹
۲-۸- تقسیم زمانی داده	۲۱
۲-۹- معیارهای ارزیابی و ابزارهای تحلیل	۲۱
۲-۱۰- ابزارهای پیاده‌سازی و ساختار نرم‌افزاری	۲۲
فصل سوم: آزمایش‌ها و ارزیابی‌ها	۲۳
۳-۱- سناریوی آزمایش	۲۳

۲۳.....	۳-۲- نتایج اعتبارسنجی (سال ۲۰۲۴).....
۲۴.....	۳-۳- انتخاب مدل نهایی و آموزش مجدد.....
۲۴.....	۳-۴- نتایج آزمون نهایی (سال ۲۰۲۵).....
۲۶.....	۳-۵- اهمیت ویژگی‌ها.....
۲۸.....	۳-۶- تحلیل روزهای پرخطا.....
۲۹.....	۳-۷- بحث و جمع‌بندی نتایج.....
۳۰.....	فصل چهارم: نتیجه‌گیری و کارهای آینده.....
۳۰.....	۴-۱- جمع‌بندی دستاوردها.....
۳۰.....	۴-۲- محدودیت‌ها.....
۳۱.....	۴-۳- پیشنهادهایی برای کارهای آینده.....
۳۲.....	۴-۴- سخن پایانی.....
۳۳.....	منابع.....
۳۵.....	پیوست: فهرست کامل ویژگی‌های تولیدشده.....

چکیده

مسئله اصلی این پژوهش، پیش‌بینی دمای میانگین روز آینده در شهر تهران بر پایه مشاهدات هواشناسی روز جاری و روزهای گذشته است؛ مسئله‌ای که به دلیل ماهیت سری‌زمانی داده‌ها، نوسان‌پذیری شرایط جوی و خطر خطاهای روش‌شناختی مانند نشی داده، با چالش‌های جدی همراه است. هدف این گزارش، طراحی، پیاده‌سازی و ارزیابی یک خط لوله کامل، قابل‌دفاع و تکرارپذیر یادگیری ماشین است که در آن مهندسی ویژگی — و نه صرفاً انتخاب الگوریتم — نقش محوری را ایفا می‌کند.

داده‌های روزانه ایستگاه مهرآباد تهران در بازه ژانویه ۲۰۲۰ تا دسامبر ۲۰۲۵ (۲۱۹۲ روز) از سرویس بازتحلیل جوی Open-Meteo مبتنی بر داده‌های ERA۵ دریافت شد؛ این منبع پس از راستی‌آزمایی کتی با داده‌های ایستگاهی (ضریب همبستگی ۰/۹۹۵ برای دما و ۰/۹۷۹ برای فشار) جایگزین منبع اولیه شد، زیرا برخلاف آن، پوشش کامل رطوبت نسبی را فراهم می‌کرد و فاقد مقدار گم‌شده بود.

روی هفت متغیر خام، در مجموع ۴۷ ویژگی در هشت خانواده (تأخیری، آماره متحرک، نرخ تغییر، فصلی، مشتق‌شده دمای، نوسان‌پذیری و روند، رطوبتی و پرچم رویداد) تولید شد که مهم‌ترین آن‌ها شاخص‌های فصلی سینوسی/کسینوسی و ویژگی‌های مبتنی بر رطوبت یعنی نقطه شبنم (فرمول Magnus) و فاصله دما تا نقطه شبنم است. در جریان توسعه، دو نقص روش‌شناختی شناسایی و اصلاح شد: نشی زمانی داده در ویژگی فشار نسبی (که با بازنویسی علی آن بر پایه میانگین متحرک ۳۶۵ روزه گذشته رفع گردید) و یک ویژگی ترکیبی بدون پایه فیزیکی که به‌طور مصنوعی بر رتبه‌بندی اهمیت ویژگی‌ها مسلط شده بود و حذف شد.

پنج مدل یادگیری ماشین (رگرسیون خطی، رگرسیون Ridge، جنگل تصادفی، تقویت گرادیان و XGBoost) به همراه مدل پایه تداوم، با تقسیم کاملاً زمانی داده آموزش و مقایسه شدند: آموزش نامزدها روی ۲۰۲۰ تا ۲۰۲۳، انتخاب مدل برتر روی اعتبارسنجی سال ۲۰۲۴ و ارزیابی نهایی بی‌طرفانه روی سال ۲۰۲۵. مدل Ridge در اعتبارسنجی بهترین بود و در آزمون نهایی به خطای میانگین مطلق ۱/۰۰۵ و خطای جذر میانگین مربعات ۱/۲۷۶ درجه سانتی‌گراد رسید که نسبت به مدل تداوم دارای بهبود ۱۵/۹۵ درصدی است. تحلیل اهمیت ویژگی‌ها با روش جای‌چینی، سازگاری کامل رتبه‌بندی با دانش هواشناسی را نشان داد (موقعیت فصلی، دمای امروز و تاریخچه کوتاه‌مدت دما در صدر) و تحلیل ۱۴۸ روز پرخطا آشکار ساخت که محدودیت اصلی مدل — مشترک میان همه مدل‌های مشاهداتی — رویدادهای ناگهانی و دوره‌های گذار فصلی است و مسیر کارهای آینده (تلفیق خروجی مدل‌های عددی پیش‌بینی جو) را مشخص می‌کند.

واژگان کلیدی: پیش‌بینی دما، یادگیری ماشین، مهندسی ویژگی، نشی داده، رگرسیون Ridge، سری زمانی هواشناسی، نقطه

شبنم، اهمیت ویژگی جای‌چینی


فصل اول: مرور ادبیات و پیشینه تحقیق

۱-۱ - مقدمه‌ای بر مسئله پیش‌بینی دما

دما، بنیادی‌ترین متغیر حالت جو است و تقریباً تمامی فرایندهای فیزیکی، بیولوژیکی و اقتصادی وابسته به هوا را متأثر می‌سازد. پیش‌بینی دمای روز آینده، ساده‌ترین شکل پیش‌بینی عددی جو در افق کوتاه است و سابقه‌ای بیش از یک قرن دارد؛ در این مدت روش‌های بسیار متنوعی — از قواعد تجربی و مدل‌های آماری ساده تا مدل‌های عددی پیچیده و الگوریتم‌های یادگیری ماشین — برای آن توسعه یافته است. اهمیت این مسئله صرفاً علمی نیست: در بخش انرژی، خطای یک درجه سانتی‌گراد در پیش‌بینی دمای روز آینده می‌تواند تقاضای برق سرمایشی و گرمایشی یک کلان‌شهر را چند درصد جابه‌جا کند و در بخش کشاورزی، پیش‌بینی نادرست شب‌های یخبندان می‌تواند خسارت جبران‌ناپذیری به باغ‌های میوه وارد کند.

از منظر روش‌شناختی، پیش‌بینی دما در سه رده کلی قرار می‌گیرد: نخست روش‌های آماری کلاسیک که بر ساختار زمانی داده‌ها تکیه دارند؛ دوم مدل‌های عددی پیش‌بینی جو (NWP) که معادلات فیزیکی حاکم بر جو را به صورت عددی حل می‌کنند؛ و سوم روش‌های یادگیری ماشین که روابط آماری میان متغیرهای مشاهده‌شده را، بدون حل صریح معادلات فیزیکی، فرامی‌آموزند^۱

شکل ۱-۱ این سه رده و نمونه‌های هر یک را به صورت یکپارچه نشان می‌دهد: جایگاه پروژه حاضر نیز در همین نقشه مشخص شده است. در ادامه بخش‌های این فصل، هر رده به تفصیل مرور می‌شود و در پایان، جدول جمع‌بندی و شکاف تحقیقاتی که پروژه به آن پاسخ می‌دهد ارائه خواهد شد.



شکل ۱-۱: دسته‌بندی کلی روش‌های پیش‌بینی دما و جایگاه پروژه حاضر

^۱ یادگیری ماشین به‌طور کلاسیک به مطالعه الگوریتم‌هایی اطلاق می‌شود که از داده‌ها (تجربه) بهبود می‌یابند؛ تعریف مرجع آن در کتاب تام میچل (Mitchell, ۱۹۹۷) ارائه شده است.

۱-۲- روش‌های آماری کلاسیک

قدیمی‌ترین و ساده‌ترین روش پیش‌بینی دما، مدل «تداوم» (Persistence) است که در آن دمای فردا برابر دمای امروز فرض می‌شود. این مدل به‌ظاهر ابتدایی، در افق‌های بسیار کوتاه عملکرد شگفت‌آوری دارد؛ زیرا جو سیستمی بزرگ با اینرسی بالاست و تغییرات ناگهانی آن نسبتاً کم‌رخدادند. به همین دلیل مدل تداوم، معیار مرجع ارزیابی در پیش‌بینی‌های کوتاه‌مدت جو شناخته می‌شود و هر مدل پیچیده تنها زمانی ارزش دارد که بتواند از آن پیشی بگیرد؛ در پروژه حاضر نیز همین مدل به‌عنوان مرجع مقایسه به کار رفته است.

نسل بعدی روش‌های آماری بر مدل‌سازی سری‌های زمانی استوار است. چارچوب کلاسیک باکس و جنکینز — شامل مدل‌های

ARIMA و توسعه فصلی آن SARIMA — سال‌ها روش استاندارد پیش‌بینی متغیرهای اقلیمی بوده است^۲

در این چارچوب، مقدار آینده متغیر به‌صورت ترکیب خطی از مقادیر گذشته خود متغیر و خطاهای گذشته مدل‌سازی می‌شود؛ نسخه چندمتغیره آن (ARIMAX) امکان ورود متغیرهای کمکی را نیز فراهم می‌کند. خانواده هم‌خانواده آن، هموارسازی نمایی است که در کتاب‌درس پیش‌بینی هایندمن و آتاناسوپولوس به‌صورت نظام‌مند و با تأکید بر اعتبارسنجی مبتنی بر افق پیش‌بینی تدوین شده است. مزیت مشترک این مدل‌ها تفسیرپذیری بالا و نیاز اندک به داده جانبی است؛ محدودیت اساسی آن‌ها اما خطی بودن ساختار است: رفتارهای غیرخطی جو — مانند اثر آستانه‌ای بارش بر دامنه دمایی یا تعامل فشار و دما — در این چارچوب ثبت نمی‌شود. دسته سوم، رگرسیون‌های چندمتغیره هستند که دمای فردا را تابعی از چند متغیر جوی روز جاری فرض می‌کنند. رگرسیون خطی ساده به دلیل فرض‌های سخت‌گیرانه (خطی بودن، استقلال خطاها و همسان‌واریانس) در مسائل واقعی هواشناسی به‌تنهایی کافی نیست، اما تفسیر مستقیم ضرایب، آن را به ابزاری برای سنجش «منطق‌مندی» رفتار مدل تبدیل کرده است. هوئزل و کنارد نشان دادند که در حضور هم‌خطی شدید میان متغیرهای پیش‌بین — وضعیتی که در داده‌های هواشناسی به‌شدت رایج است، زیرا دمای امروز با دمای دیروز، میانگین هفتگی و میانگین ماهانه هم‌بستگی‌های نزدیک به یک دارند — رگرسیون Ridge با افزودن جریمه L_2 به تابع خطا، ضرایب را منقبض کرده و پایداری و تعمیم‌پذیری مدل را به‌طور چشمگیری بهبود می‌دهد^۳

۱-۳- مدل‌های عددی پیش‌بینی جو (NWP)

مدل‌های عددی پیش‌بینی جو، ستون فقرات پیش‌بینی هوای مدرن‌اند. این مدل‌ها با گسسته‌سازی معادلات ناویر-استوکس، ترمودینامیک و تابش روی شبکه‌های سه‌بعدی و با داده‌ی مشاهداتی اولیه (داده‌کاوی)، وضعیت آینده جو را شبیه‌سازی می‌کنند. باور و همکاران در مروری جامع در نشریه Nature نشان دادند که پیش‌بینی عددی جو در نیم‌قرن گذشته «انقلاب آرامی» را تجربه

^۲ مرجع بنیادین این چارچوب، کتاب Time Series Analysis: Forecasting and Control اثر جورج باکس و گوئلم جنکینز (نخستین ویرایش ۱۹۷۰) است.

^۳ مقاله مرجع: Hoerl, A. E., & Kennard, R. W. (۱۹۷۰). Ridge regression: Biased estimation for nonorthogonal problems. Technometrics, ۱۲(۱), ۵۵-۶۷.

کرده است: رشد نمایی توان محاسباتی، بهبود مدل سازی فیزیکی و انباشت مشاهدات ماهواره ای، مهارت پیش بینی را به گونه ای بالا برده که امروزه پیش بینی سه روزه دما به دقت پیش بینی ۲۴ ساعته در دهه ۱۹۷۰ رسیده است^۴

این مدل ها با این حال محدودیت های بنیادین دارند. لورنتس با کشف ماهیت آشوبناک جو نشان داد که خطای کوچک در شرایط اولیه به صورت نمایی رشد می کند و سقف نظری پیش بینی قطعی جو حدود دو هفته است^۵

افزون بر این، اجرای مدل های NWP به منابع محاسباتی عظیم و داده های مشاهداتی جهانی نیاز دارد و خروجی خام آن ها در مقیاس شهری، به دلیل وضوح مکانی محدود، نیازمند پس پردازش آماری (آمار خروجی مدل یا MOS) است. همین نقطه — یعنی پس پردازش و برآورد در مقیاس محلی — دقیقاً جایی است که روش های آماری و یادگیری ماشین جایگاه اصلی خود را دارند؛ پروژه حاضر نیز از همین منظر قابل تبیین است، هرچند به جای خروجی NWP مستقیماً از مشاهدات روزانه بهره می گیرد و در بخش کارهای آینده، تلفیق با خروجی NWP پیشنهاد شده است.

۱-۴- شبکه های عصبی و یادگیری عمیق

نخستین موج کاربرد یادگیری ماشین در پیش بینی دما بر شبکه های عصبی تغذیه پسند (MLP) متمرکز بود. الشمیسی و همکاران با آموزش شبکه عصبی بر داده های اقلیمی ابوظبی نشان دادند که این شبکه ها می توانند دما را با دقتی بهتر از رگرسیون چندگانه پیش بینی کنند؛ هرچند تنظیم ساختار شبکه فرایندی آزمون و خطا پذیر و حساس بود. توسعه بعدی، شبکه های بازگشتی و به ویژه LSTM است که به طور ذاتی برای ثبت وابستگی های زمانی بلندمدت طراحی شده اند^۶

مطالعات متعدد پیش بینی دما و بارش با LSTM، عملکردی بهتر از ARIMA گزارش کرده اند؛ به ویژه هنگامی که توالی طولانی روزهای گذشته به صورت خام وارد مدل می شود. موج جدیدتر، معماری های مبتنی بر توجه (Transformer) و مدل های یادگیری عمیق داده محور مقیاس بزرگ اند که در سال های اخیر برای پیش بینی جو در مقیاس جهانی با مدل های عددی رقابت کرده اند. با این حال، سه محدودیت عملی این خانواده برای پروژه های دانشگاهی کوچک جدی است: نیاز به داده بسیار بیشتر، حساسیت بالا به تنظیم ابرپارامترها و تفسیرناپذیری نسبی؛ به همین دلیل در این پروژه، خانواده های یادگیری ماشین جدولی (خطی و درختی) به عنوان نامزدهای اصلی انتخاب شدند و شبکه های عمیق به کارهای آینده واگذار شدند.

۴. Bauer, P., Thorpe, A., & Brunet, G. (۲۰۱۵). The quiet revolution of numerical weather prediction. *Nature*, ۵۲۵(۷۵۶۷), ۴۷-۵۵

۵. Lorenz, E. N. (۱۹۶۳). Deterministic nonperiodic flow. *Journal of the Atmospheric Sciences*, ۲۰(۲), ۱۳۰-۱۴۱

۶. Hochreiter, S., & Schmidhuber, J. (۱۹۹۷). Long short-term memory. *Neural Computation*, ۹(۸), ۱۷۳۵-۱۷۸۰

۱-۵- مدل‌های مبتنی بر درخت و تقویت گرادیان

دومین موج اثرگذار یادگیری ماشین، الگوریتم‌های مبتنی بر درخت تصمیم بودند. بریمان با معرفی جنگل تصادفی نشان داد که میانگین‌گیری از پرشمار درخت رگرسیونی آموزش‌دیده روی زیرنمونه‌های تصادفی از داده و ویژگی‌ها، واریانس مدل را به‌طور چشمگیری کاهش می‌دهد و مقاومت خوبی در برابر بیش‌برازش فراهم می‌کند^۷

فریدمن رویکرد تقویت گرادیان را معرفی کرد که در آن درخت‌های کوچک به‌صورت مرحله‌ای در جهت منفی گرادیان تابع خطا ساخته می‌شوند و توانایی استثنایی در مدل‌سازی روابط غیرخطی و تعاملی دارند. چن و گسترین با پیاده‌سازی بهینه‌شده XGBoost — شامل جریمه پیچیدگی درخت، نمونه‌گیری ستونی و پردازش موازی — این خانواده را به یکی از پرکاربردترین ابزارهای یادگیری ماشین جدولی تبدیل کردند^۸

در مطالعات پیش‌بینی دما، الگوریتم‌های درختی معمولاً از رگرسیون خطی و ARIMA بهتر عمل کرده‌اند؛ به‌ویژه هنگامی که رویدادهای خاص (بارش، پوشش ابر) اثر غیرخطی بر دما دارند. نکته‌ای که تقریباً در تمامی مطالعات مشترک است، فقدان «الگوریتم برتر همیشگی» است: رفتار مدل‌های درختی در برون‌یابی شرایط نادیده (مانند موج سرمای بی‌سابقه) ضعیف است، مدل‌های خطی روابط تعاملی را نمی‌بینند و مدل‌های عمیق به داده بلندمدت نیاز دارند. به همین دلیل، ادبیات جدید به جای تمرکز صرف بر «انتخاب مدل»، به سمت «کیفیت ورودی مدل» یعنی مهندسی ویژگی و صحت روش شناختی چرخه داده حرکت کرده است — همان محوری که پروژه حاضر بر آن بنا شده است.

۱-۶- مهندسی ویژگی در سری‌های زمانی هواشناسی

در مسائل سری‌های زمانی هواشناسی، مهندسی ویژگی سه نقش کلیدی دارد. نخست، بازنمایی صریح ساختار زمانی: تبدیل مشاهدات خام به تأخیرها، میانگین‌ها و شیب‌های متحرک به هر مدل — حتی مدل خطی — امکان می‌دهد رابطه «دمای امروز با دمای فردا» را مستقیماً بیاموزد. دوم، بازنمایی چرخه‌های طبیعی: کدگذاری روز سال با توابع سینوسی و کسینوسی، پیوستگی انتقال سال نو (۳۱ دسامبر به ۱ ژانویه) را حفظ می‌کند و به مدل اجازه می‌دهد تناوب فصلی را به‌صورت عددی — و نه رسته‌ای — بیاموزد؛ مزیت این کدگذاری بر شماره خام روز سال در ادبیات پیش‌بینی فصلی به خوبی مستند است. سوم، تزریق دانش دامنه: کمیت‌هایی مانند نقطه شبنم — که از دما و رطوبت نسبی با فرمول Magnus–Tetens محاسبه می‌شود — اطلاعات فیزیکی معناداری درباره پایداری جو و پتانسیل سرمای‌ش شبانه حمل می‌کنند^۹

۷ Breiman, L. (۲۰۰۱). Random forests. Machine Learning, ۴۵(۱), ۵-۳۲. همین مقاله، بنیان روش اهمیت جای‌چینی است که در فصل سوم این گزارش برای تفسیر مدل به کار رفته است.

۸ Chen, T., & Guestrin, C. (۲۰۱۶). XGBoost: A scalable tree boosting system. Proceedings of the ۲۲nd ACM SIGKDD, ۷۸۵-۷۹۴

۹ تبدیل رطوبت نسبی به نقطه شبنم و بحث دقت فرمول‌های Magnus در: Lawrence, M. G. (۲۰۰۵). The relationship between relative humidity and the dewpoint temperature in moist air. Bulletin of the American Meteorological Society, ۸۶(۲), ۲۲۵-۲۳۴

تجربه جمعی این مطالعات نشان می‌دهد کیفیت ویژگی‌ها اغلب مهم‌تر از پیچیدگی مدل است: یک مدل خطی با ویژگی‌های غنی و درست، می‌تواند هم‌ارز یا بهتر از مدل پیچیده‌ای عمل کند که تنها داده خام دریافت می‌کند. همین مشاهده، تصمیم طراحی این پروژه — سرمایه‌گذاری اصلی روی مهندسی ویژگی و انتخاب مدل‌های نسبتاً ساده و تفسیرپذیر — را توجیه می‌کند.

۱-۷- داده‌های بازتحلیل جو و ارتباط‌های برنامه‌نویسی هواشناسی

از منظر منبع داده، ظهور سرویس‌های بازتحلیل جوی مانند ERA۵ و رابط‌های برنامه‌نویسی رایگانی مانند Open-Meteo، دسترسی به داده‌های هواشناسی باکیفیت، یکنواخت و بدون مقدار گم‌شده را دموکراتیزه کرده است. ERA۵ بازتحلیل جو سیاره‌ای است که با ترکیب مدل عددی جو و میلیون‌ها مشاهده ایستگاهی، ماهواره‌ای و رادیوزنده‌ای، بازسازی یکپارچه‌ای از وضعیت جو از ۱۹۴۰ تا امروز ارائه می‌دهد و به همین دلیل، مرجع استاندارد مطالعات اقلیمی و یادگیری ماشین جو شده است.^{۱۰}

داده‌های بازتحلیل پوشش زمانی و مکانی کامل و سازگاری درونی بالا دارند؛ اما در متغیرهای محلی مانند سرعت باد — که به ریزمقیاس توپوگرافی و ساختارهای شهری حساس است — همبستگی ضعیف‌تری با مشاهدات نقطه‌ای دارند؛ محدودیتی که در پروژه حاضر نیز به صورت کئی (همبستگی ۰/۶۱۴ برای باد در برابر داده ایستگاهی) مشاهده و مستند شد و در فصل چهارم به آن پرداخته شده است.

۱-۸- مسئله نشتی داده در ارزیابی مدل‌های سری زمانی

مسئله‌ای که در ادبیات کاربردی کمتر به آن پرداخته می‌شود ولی در مسائل سری زمانی حیاتی است، نشتی داده (Data Leakage) است: ورود اطلاعات مربوط به فرایند ارزیابی — مستقیم یا از مسیر ساخت ویژگی — به فرایند آموزش، که مدل را به عملکردی کاذب و غیرقابل تکرار در شرایط واقعی می‌رساند. کافمن و همکاران این پدیده را به صورت صوری صورت‌بندی کرده‌اند و نشان می‌دهند که حتی نشتی‌های ظریف می‌توانند ارزیابی را کاملاً بی‌اعتبار کنند.^{۱۱}

در مسائل سری زمانی هواشناسی، سه مسیر رایج نشتی عبارت‌اند از: تقسیم تصادفی داده (که نمونه‌های همسایه زمانی را دو سمت مرز آموزش و آزمون می‌گذارد)، محاسبه آماره‌های ویژگی روی کل بازه به جای پنجره‌های گذشته (نمونه کلاسیک: نرمال‌سازی یا میانگین‌گیری پیش از تفکیک) و ویژگی‌هایی که ناخواسته حاوی اطلاعات هدف‌اند. پادزهر استاندارد این سه، به ترتیب: تقسیم کاملاً زمانی، علی‌بودن تمامی محاسبات ویژگی و بازبینی نقادانه اهمیت ویژگی‌ها در برابر منطق فیزیکی است؛ هر سه در روش پیشنهادی این پروژه (فصل دوم) به عنوان قواعد سخت طراحی اعمال شده‌اند.

Hersbach, H., et al. (۲۰۲۰). The ERA۵ global reanalysis. Quarterly Journal of the Royal Meteorological Society, ۱۴۶(۷۳۰), ۱۹۹۹-۱۰۲۰۴۹.

Kaufman, S., Rosset, S., & Perlich, C. (۲۰۱۱). Leakage in data mining: Formulation, detection, and avoidance. ACM Transactions on Management Information Systems, ۲(۳), Article ۱۵.

۱-۹- مطالعات مرتبط در ایران و منطقه تهران

تهران به دلیل قرارگیری در دامنه جنوبی رشته‌کوه البرز، همسایگی با حوضه کویری و وجود جزیره گرمایی شهری گسترده، الگوی دمایی پیچیده و پرنوسانی دارد: تفاوت دمای شبانه‌روزی میان نواحی ارتفاعات شمالی و حاشیه جنوبی گاه به چند درجه می‌رسد، وارونگی دمای زمستانه آلودگی هوا را تشدید می‌کند و ورود سامانه‌های سرد شمال‌غربی می‌تواند طی چند ساعت دما را ده درجه تغییر دهد. مطالعات اقلیمی متعدد، ساختار فصلی دمای تهران را مستند کرده‌اند: تابستان‌های گرم و خشک با دامنه شبانه‌روزی بالا، زمستان‌های سرد با ریسک یخبندان و دوره‌های گذار بهار و پاییز با بیشترین نوسان‌پذیری. همین نوسان‌پذیری بالای دوره‌های گذار، پیش‌بینی دما را در ماه‌های فروردین تا خرداد و مهر تا آذر به چالشی جدی تبدیل می‌کند — الگویی که در نتایج فصل سوم این گزارش نیز به صورت کئی بازتولید شد.

۱-۱۰- جمع‌بندی مرور ادبیات و شکاف تحقیقاتی

جدول ۱-۱ خلاصه رده‌های مرور شده، نقاط قوت و محدودیت‌های هر رده را کنار هم قرار می‌دهد.

جدول ۱-۱: جمع‌بندی رده‌های روش‌های پیش‌بینی دما در ادبیات

رده	نمایندگان شاخص	نقاط قوت	محدودیت‌ها
آماري کلاسیک	تداوم، ARIMA/SARIMA، رگرسیون، Ridge	ساده، تفسیرپذیر، کم‌نیاز به داده	ساختار خطی؛ ناتوان از روابط تعاملی
عددی (NWP)	GFS، ECMWF، MOS	دقت بالا در افق چندروزه؛ داده سه‌بعدی جو	هزینه محاسباتی عظیم؛ نیاز به پس‌پردازش محلی
شبکه‌های عصبی	MLP، LSTM، Transformer	یادگیری خودکار توابع غیرخطی پیچیده	داده‌بر، حساس به تنظیم، تفسیرناپذیر
درخت‌محور	جنگل تصادفی، تقویت گرادیان، XGBoost	غیرخطی، مقاوم، بدون نیاز به مقیاس‌دهی	برون‌یابی ضعیف در شرایط نادیده
پروژه حاضر	مهندسی ویژگی علی + مدل‌های خطی و درختی	دقت رقابتی، تفسیرپذیر، تکرارپذیر، بدون نشتی	فقط تهران و افق یک‌روزه (محدودیت پذیرفته‌شده)

از این مرور، چهار نتیجه کلیدی استخراج می‌شود. نخست، پیش‌بینی یک‌روزه دما مسئله‌ای است که مدل‌های ساده خطی — در صورت بهره‌گیری از ویژگی‌های مناسب — می‌توانند در آن عملکردی رقابتی و تفسیرپذیر ارائه دهند. دوم، مقایسه نظام‌مند خانواده‌های خطی و درختی روی مجموعه ویژگی مشترک، رویه استاندارد مطالعات معتبر است. سوم، مهندسی ویژگی مبتنی بر دانش دامنه — تأخیرها، آماره‌های متحرک، کدگذاری فصلی و کمیت‌های مشتق‌شده فیزیکی مانند نقطه شبنم — همواره بخشی از مدل‌های موفق بوده است. چهارم، صحت روش شناختی (تقسیم زمانی، علی‌بودن ویژگی‌ها، پرهیز از نشتی داده) در ادبیات کمتر به صورت کئی و مستند گزارش می‌شود، در حالی که نقص در این بخش می‌تواند تمامی نتایج را بی‌اعتبار کند.


شکاف تحقیقاتی‌ای که پروژه حاضر می‌کوشد پر کند، ترکیب این چهار رشته در یک چارچوب واحد و شفاف است: مقایسه نظام‌مند پنج خانواده مدل روی یک مجموعه ویژگی مشترک و علی، مرجع‌گذاری با مدل تداوم، مستندسازی صریح فرایند شناسایی و رفع دو نقص روش‌شناختی و تحلیل تفصیلی خطاها بر پایه شرایط جوی روزهای پرخطا؛ ترکیبی که گزارش را از یک «مقایسه الگوریتم‌ها» به یک «مطالعه مهندسی کامل چرخه داده» ارتقا می‌دهد.

فصل دوم: روش پیشنهادی

۲-۱- بیان رسمی مسئله

مسئله پیش‌بینی در این پژوهش به صورت زیر تعریف می‌شود: با داشتن توالی مشاهدات هواشناسی روزانه از ابتدای بازه تا روز t — شامل دمای میانگین، کمینه و بیشینه، بارش، سرعت باد، فشار سطح دریا و رطوبت نسبی — مقدار دمای میانگین روز $t+1$ برآورد شود. به بیان ریاضی، در هر روز t بردار ویژگی $x(t)$ ساخته می‌شود که هر مؤلفه آن تابعی فقط از مقادیر روزهای $t-2$ ، $t-1$ ، t و قبل از آن‌ها است (خاصیت علی بودن) و مدل f تابعی است که برآورد $\hat{y}(t) = f(x(t))$ را تولید می‌کند؛ هدف، کمینه‌سازی خطای $|y(t) - \hat{y}(t)|$ است که در آن $y(t)$ دمای واقعی میانگین روز $t+1$ است.

دو نکته در این تعریف اهمیت روش‌شناختی دارد. نخست آن‌که مدل به هیچ‌کدام از خروجی‌های پیش‌بینی عددی جو دسترسی ندارد و صرفاً از مشاهدات زمینی گذشته بهره می‌گیرد؛ بنابراین معیار درست ارزیابی، «بهبود نسبت به مدل تداوم» است، نه مقایسه با پیش‌بینی‌های عملیاتی. دوم آن‌که همه ویژگی‌ها باید پیش از رسیدن داده روز $t+1$ قابل محاسبه باشند؛ این الزام — که مستقیماً از ادبیات نشتی داده (بخش ۸-۱) استخراج شده — قاعده‌ای سخت‌گیرانه اما ضروری است که در طراحی تمام ۴۵ ویژگی رعایت شده است.



Next-Day Mean Temperature Prediction Pipeline — Tehran Mehrabad (2020-2025)

شکل ۲-۱: معماری کلی خط لوله پیشنهادی از دریافت داده تا ارزیابی مدل

۲-۲- معماری کلی خط لوله پیشنهادی

روش پیشنهادی از شش مرحله متوالی تشکیل شده است (شکل ۲-۱): (۱) دریافت داده‌های روزانه از API آرشیو Open-Meteo؛ (۲) پاک‌سازی و پیش‌پردازش شامل بازنام‌گذاری ستون‌ها، مرتب‌سازی زمانی و پالایش مقادیر گمشده؛ (۳) مهندسی ویژگی با تولید ۴۷ ویژگی در هشت خانواده؛ (۴) تقسیم زمانی داده به چهار مجموعه آموزش، اعتبارسنجی، آموزش نهایی و آزمون؛ (۵) آموزش و مقایسه پنج مدل یادگیری ماشین به همراه مدل تداوم؛ و (۶) ارزیابی نهایی، تحلیل اهمیت ویژگی‌ها و تحلیل خطا. هر یک از این مراحل در بخش‌های بعدی این فصل به تفصیل شرح داده می‌شود.

تمامی مراحل در قالب مازول‌های مجزای پایتون پیاده‌سازی شده‌اند تا امکان تکرار، بازبینی و توسعه آینده فراهم باشد؛ جدول ۲-۸ در انتهای فصل، نقش هر مازول را فهرست می‌کند. این ساختار مازولار، هم‌زمان سه هدف را دنبال می‌کند: تکرارپذیری کامل نتایج

(اجرای مجدد کل چرخه با یک دستور)، جداسازی دغدغه‌ها (منطق ویژگی‌ها جدا از منطق آموزش) و قابلیت گسترش (افزودن مدل یا ویژگی جدید بدون دستکاری بقیه خط لوله).

۲-۳- داده‌ها

۲-۳-۱- منبع داده و روند انتخاب آن

منبع اولیه داده‌های این پروژه، پایگاه ایستگاهی Meteostat برای ایستگاه فرودگاه مهرآباد تهران بود. در فرایند بازبینی داده مشخص شد این منبع برای بازه موردنظر فاقد داده رطوبت نسبی است؛ در حالی که رطوبت در طرح اولیه پروژه به‌عنوان یکی از پارامترهای ورودی ذکر شده بود و از منظر فیزیکی (پتانسیل سرمایش شبانه، پوشش ابر، سنجش خشکی هوا) متغیری ارزشمند است. برای رفع این شکاف، منبع داده به API آرشیو هواشناسی Open-Meteo تغییر یافت؛ سرویسی رایگان که داده‌های خود را از بازتحلیل جهانی ERA۵ می‌گیرد و علاوه بر پوشش کامل رطوبت، در بازه موردنظر فاقد هرگونه مقدار گم‌شده است^{۱۲}

پیش از جایگزینی کامل منبع، اعتبار داده جدید با مقایسه مستقیم با داده ایستگاهی قدیم راستی‌آزمایی شد. برای سه متغیر اصلی، ضریب همبستگی پیرسون و خطای میانگین مطلق میان دو منبع محاسبه شد (جدول ۱-۲). همبستگی دما (۰/۹۹۵) و فشار سطح دریا (۰/۹۷۹) — دو متغیری که در نهایت مهم‌ترین نقش را در مدل ایفا کردند — بسیار بالا و کاملاً قابل اعتماد است. همبستگی ضعیف‌تر سرعت باد (۰/۶۱۴) محدودیت شناخته‌شده داده‌های بازتحلیل است: وضوح مکانی ERA۵ حدود ۹ تا ۲۵ کیلومتر است و اثرات میکرومقیاسی محوطه فرودگاه (بادهای محلی، توپوگرافی ریز) در آن ثبت نمی‌شود؛ این موضوع در فصل چهارم به‌عنوان محدودیت پروژه بحث شده است.

جدول ۱-۲: راستی‌آزمایی داده Open-Meteo در برابر داده ایستگاهی Meteostat

متغیر	ضریب همبستگی با داده ایستگاهی	خطای میانگین مطلق بین دو منبع
دمای میانگین روزانه	۰/۹۹۵	۱/۰۳ درجه سانتی‌گراد
فشار سطح دریا	۰/۹۷۹	۱/۹۱ هکتوپاسکال
سرعت باد	۰/۶۱۴	۴/۲۳ کیلومتر بر ساعت

۲-۳-۲- مشخصات دیتاست نهایی

دیتاست نهایی شامل ۲۱۹۲ روز نمونه (از ۱ ژانویه ۲۰۲۰ تا ۳۱ دسامبر ۲۰۲۵) با هفت متغیر خام روزانه است. جدول ۲-۲ مشخصات کلی و جدول ۳-۲ آمار توصیفی متغیرهای خام را نشان می‌دهد. میانگین دمای دوره ۱۸/۵ درجه سانتی‌گراد است که با اقلیم نیمه‌خشک تهران سازگار است؛ دامنه دمایی مشاهده‌شده (از ۲/۹- تا ۳۶/۸+) گستره وسیع شرایط جوی پوشش داده‌شده توسط داده‌های آموزشی را نشان می‌دهد که برای تعمیم‌پذیری مدل مزیت محسوب می‌شود. متوسط رطوبت نسبی نسبتاً پایین (۳۳/۳ درصد) ویژگی اقلیمی بارز تهران است و ارزش افزودن ویژگی‌های مبتنی بر رطوبت را توجیه می‌کند.

^{۱۲} مستندات سرویس: <https://open-meteo.com/en/docs/historical-weather-api>; Open-Meteo. Historical Weather API Documentation.

جدول ۲-۲: مشخصات کلی دیتاست نهایی

ویژگی	مقدار
موقعیت جغرافیایی	تهران، ایستگاه مهرآباد (۳۵/۶۸۹۲ شمالی، ۵۱/۳۱۳۴ شرقی)
بازه زمانی	۲۰۲۰-۰۱-۰۱ تا ۲۰۲۵-۱۲-۳۱
تعداد رکورد	۲۱۹۲ روز
فراوانی نمونه برداری	روزانه
متغیرهای خام	دمای میانگین/کمینه/بیشینه، بارش، سرعت باد، فشار سطح دریا، رطوبت نسبی
مقادیر گمشده	صفر (داده بازتحلیل ERA۵)
متغیر هدف	دمای میانگین روز بعد
منبع داده	Open-Meteo Historical Weather API (مبتنی بر ERA۵)

جدول ۲-۳: آمار توصیفی متغیرهای خام بازه ۲۰۲۰ تا ۲۰۲۵

متغیر	واحد	میانگین دوره	کمینه	بیشینه
دمای میانگین (tavg)	درجه سانتی گراد	۱۸/۵	-۲/۹	۳۶/۸
رطوبت نسبی (rh)	درصد	۳۳/۳	—	—
فشار سطح دریا (pres)	هکتوپاسکال	۱۰۱۳/۵	—	—
سرعت باد (wspd)	کیلومتر بر ساعت	۷/۷	—	—
بارش تجمعی دوره (prcp)	میلی متر	۱۷۳۲/۵ (مجموع)	—	—

۳-۳-۲- دریافت خودکار داده‌ها

دریافت داده‌ها به صورت خودکار و تکرارپذیر انجام می‌شود: اسکریپت `download_data.py` با یک درخواست HTTP به نقطه انتهایی آرشیو Open-Meteo، متغیرهای روزانه را برای مختصات تهران و بازه زمانی موردنظر به صورت CSV دریافت و در پوشه `data` ذخیره می‌کند. جدول ۲-۴ پارامترهای کلیدی این درخواست را فهرست می‌کند. دریافت متغیرهای اضافی (برف، جهت باد غالب، تندباد، ساعات آفتابی) به عنوان ظرفیت توسعه آینده در نظر گرفته شده و در نسخه فعلی مدل استفاده نمی‌شوند.

جدول ۲-۴: پارامترهای درخواست داده از API آرشیو Open-Meteo

پارامتر	مقدار	توضیح
latitude / longitude	35.6892 / 51.3134	مختصات ایستگاه مهرآباد تهران
start_date / end_date	2020-01-01 / 2025-12-31	بازه شش ساله داده

پارامتر	مقدار	توضیح
daily	۱۱ متغیر روزانه	دما (میانگین/کمینه/بیشینه)، بارش، برف، جهت باد، سرعت باد، تندباد، فشار، رطوبت، ساعات آفتابی
timezone	Asia/Tehran	منطقه زمانی محلی
format	csv	قالب خروجی

۲-۴- پیش‌پردازش داده

گرچه داده بازتحلیل نهایی فاقد مقدار گمشده است، خط لوله پیش‌پردازش به‌گونه‌ای طراحی شده که در برابر داده‌های ورودی ناقص مقاوم باشد و در صورت استفاده از منابع دیگر نیز صحت محاسبات پنجره‌ای حفظ شود. گام‌های پیش‌پردازش به ترتیب اجرا عبارت‌اند از:

- **گام ۱** — مرتب‌سازی رکوردها بر اساس تاریخ برای تضمین صحت محاسبات تأخیری و پنجره‌ای؛ هرگونه جابه‌جایی در ترتیب زمانی، تمامی ویژگی‌های lag و rolling را مخدوش می‌کند.
 - **گام ۲** — درون‌یابی خطی برای ستون‌های پیوسته (دما، باد، فشار، رطوبت) در صورت وجود شکاف کوتاه؛ درون‌یابی در هر دو جهت اعمال می‌شود تا شکاف‌های ابتدا و انتهای بازه نیز پوشش داده شوند.
 - **گام ۳** — پر کردن مقادیر باقی‌مانده با میانه ستون مربوطه؛ میانه به دلیل مقاومت در برابر داده پرت به میانگین ترجیح داده شد.
 - **گام ۴** — مقداردهی صفر به بارش گزارش‌نشده؛ در داده‌های هواشناسی، نبود گزارش بارش عملاً به معنای نبود بارش است و مقدار گمشده برای این ستون معنای فیزیکی ندارد.
- نکته مهم این است که هر چهار گام «پیش از» ساخت ویژگی و صرفاً بر داده ورودی اعمال می‌شوند و هیچ‌کدام از آماره‌ای از کل بازه برای بازنویسی مقادیر استفاده نمی‌کنند؛ بنابراین حتی پیش‌پردازش نیز از منظر نشتی داده ایمن طراحی شده است.

۲-۵- مهندسی ویژگی

قلب روش پیشنهادی، مرحله مهندسی ویژگی است. از هفت متغیر خام تمیزشده، در مجموع ۴۷ ویژگی در هشت خانواده ساخته می‌شود که پس از کنار گذاشتن دو ستون زائد (سال و شماره خام روز سال که جای خود را به بازنمایی سینوسی/کسینوسی داده‌اند)، ۴۵ ویژگی وارد مدل می‌شوند. قاعده حاکم بر تمامی ویژگی‌ها علی‌بودن است: هر ویژگی تنها از مقادیر روز جاری و گذشته محاسبه می‌شود. در ادامه هر خانواده به تفصیل شرح داده می‌شود و جدول ۲-۵ جمع‌بندی آن‌ها را ارائه می‌کند.

۱-۲-۵- ویژگی‌های تأخیری (Lag)

ساده‌ترین و مؤثرترین خانواده، مقادیر گذشته خود متغیرهاست: دمای میانگین روزهای ۱، ۲، ۳، ۷ و ۱۴ روز قبل به‌عنوان پنج ویژگی مستقل وارد مدل می‌شوند. انتخاب پنجره‌ها ترکیبی از اهمیت کوتاه‌مدت (اینرسی جو در ۱ تا ۳ روز) و رویدادهای هفتگی-ده‌روزه است.

۲-۲-۵- آماره‌های متحرک (Rolling)

برای دمای میانگین، میانگین و انحراف معیار متحرک در چهار پنجره ۳، ۷، ۱۴ و ۳۰ روزه ساخته شده است (هشت ویژگی). نکته فنی مهم آن است که همه آماره‌های متحرک با یک روز تأخیر محاسبه می‌شوند؛ یعنی میانگین متحرک ۷ روزه در روز t ، میانگین دمای روزهای $t-1$ تا $t-7$ است و روز t را شامل نمی‌شود. این تأخیر، تضمین می‌کند که تعریف متغیر هدف (دمای فردا) هرگز در محاسبه ویژگی‌ها دخیل نشود. میانگین‌های متحرک «سطح فعلی» دما را به مدل می‌دهند و انحراف معیارهای متحرک «نوسان‌پذیری» محیط را — کمیتی که در تابستان پایدار کم و در دوره‌های گذار زیاد است.

۳-۲-۵- ویژگی‌های نرخ تغییر (Change)

چهار ویژگی این خانواده، تفاضل اول و سوم دما (تغییر یک‌روزه و سه‌روزه) و تفاضل یک‌روزه فشار و باد هستند. تغییر فشار به‌ویژه حائز اهمیت است: ورود سامانه‌های جوی با افت محسوس فشار سطح دریا همراه است و همین افت، پیش‌نشانگر تغییرات شدید دماست. تحلیل خطاها در فصل سوم نشان می‌دهد که مدل دقیقاً در روزهایی ضعیف‌تر است که این پیش‌نشانگرها کفایت نکرده‌اند.

۴-۲-۵- ویژگی‌های فصلی و زمانی

چرخه سالانه دما با توابع سینوسی و کسینوسی روز سال بازنمایی می‌شود: $\text{doy_sin} = \sin(2\pi \cdot \text{doy}/366)$ و $\text{doy_cos} = \cos(2\pi \cdot \text{doy}/366)$. مزیت این کدگذاری بر شماره خام روز سال، پیوستگی آن است: در ۳۱ دسامبر و ۱ ژانویه شماره خام از ۳۶۶ به ۱ می‌پرد، اما بازنمایی سینوسی/کسینوسی نقطه‌ای پیوسته روی دایره واحد است و مدل بدون شکاف می‌آموزد که این دو روز اقلیمی به هم چسبیده‌اند. ماه تقویمی و دو پرچم دودویی زمستان (دسامبر تا فوریه) و تابستان (ژوئن تا اوت) نیز افزوده شده‌اند تا دوره‌های دارای رفتار خاص (مانند وارونگی دما در زمستان) صریحاً به مدل معرفی شوند. ستون‌های خام «سال» و «شماره روز سال» از ورودی مدل حذف شده‌اند: سال خام به دلیل فقدان تعمیم‌پذیری به آینده و شماره خام روز به دلیل جایگزینی با بازنمایی بهتر.

۵-۲-۵- ویژگی‌های مشتق‌شده دمایی و تعاملی

سه ویژگی ساده اما کارآمد این خانواده عبارت‌اند از: دامنه دما (تفاضل بیشینه و کمینه)، نقطه میانی دما (میانگین بیشینه و کمینه) و پرچم بارش (بودن یا نبودن بارش روز). دامنه دما وضعیت پوشش ابر و رطوبت خاک را به‌طور ضمنی بازتاب می‌دهد و پرچم بارش، اثر سرمایشی بارش را در قالبی ساده برای مدل خطی قابل استفاده می‌کند. حاصل ضرب دامنه دما در پرچم بارش (تعامل بارش و

دامنه) نیز به عنوان ویژگی تعاملی افزوده شده است؛ این تعامل نشان می‌دهد بارش در روزهای با دامنه بالا اثر سرمایشی متفاوتی دارد.

۶-۵-۲- ویژگی‌های نوسان‌پذیری و روند

دو ویژگی نوسان‌پذیری (انحراف معیار متحرک هفت‌روزه دما و فشار) و دو ویژگی روند (شیب خط برازش شده بر داده سه‌روزه و هفت‌روزه گذشته دما با کمینه‌سازی مربعات) ساخته شده‌اند. شیب هفت‌روزه «مومنتوم» دما را می‌سنجد: اگر دما طی هفته گذشته به‌طور پیوسته صعودی بوده، این ویژگی به مدل کمک می‌کند صعود را ادامه دهد. علاوه بر این، انحراف دمای امروز از میانگین ۳۰ روزه گذشته محاسبه می‌شود که «غیرعادی بودن» وضعیت جو نسبت به هفته‌های اخیر را کمی می‌کند؛ شمارش روزهای بارانی هفته گذشته نیز به عنوان ویژگی تداوم رطوبتی افزوده شده است.

۷-۵-۲- ویژگی‌های مبتنی بر رطوبت (نقطه شبنم)

پس از انتقال منبع داده و دستیابی به رطوبت نسبی، چهار ویژگی جدید اضافه شد. نخست، نقطه شبنم که با فرمول Magnus-Tetens از دما و رطوبت نسبی محاسبه می‌شود: $\gamma = \ln(RH/100) + a \cdot T / (b + T)$ و سپس $T_{dp} = b \cdot \gamma / (a - \gamma)$ با ثابت‌های $a = 17.62$ و $b = 243.12$ (برای جلوگیری از لگاریتم صفر، رطوبت به بازه ۱ تا ۱۰۰ درصد محدود شده است). نقطه شبنم کمیت فیزیکی حقیقی است و محتوای رطوبت مطلق هوا را نشان می‌دهد. دوم، فاصله دما تا نقطه شبنم که معیار خشکی هواست: هرچه این فاصله بیشتر، هوای خشک‌تر و سرمایش شبانه تابشی سریع‌تر است. سوم و چهارم، تأخیر یک‌روزه و میانگین متحرک هفت‌روزه رطوبت نسبی، مشابه ساختار ویژگی‌های دمایی.

۸-۵-۲- پرچم‌های رویداد و فشار نسبی

دو ویژگی باقیمانده ماهیت «پرچم رویداد» دارند. پرچم دمای غیرعادی، یک است که اگر انحراف مطلق دمای امروز از میانگین ۳۰ روزه گذشته از دو برابر انحراف معیار همان پنجره بیشتر باشد؛ این پرچم به مدل اعلام می‌کند در وضعیت غیرمعمول قرار است و اعتماد به تداوم باید کاهش یابد. ویژگی فشار نسبی نیز انحراف فشار امروز از میانگین فشار یک‌سال گذشته را می‌سنجد؛ نسخه اصلاح شده این ویژگی (بخش ۲-۶-۱) از نمونه‌های آموزشی مهم پروژه است.

جدول ۲-۵: خلاصه خانواده‌های ویژگی و منطق طراحی آن‌ها

خانواده	نمونه ویژگی‌ها	منطق / هدف
تأخیری	tavg_lag_1, tavg_lag_3, tavg_lag_7, tavg_lag_14	وابستگی دمای فردا به دمای روزهای اخیر
آماره متحرک	tavg_roll_7_mean, tavg_roll_30_std	سطح فعلی و نوسان دما در پنجره‌های متعدد
نرخ تغییر	tavg_change_1d, pressure_change_1d, wind_change_1d	پیش‌نشانگرهای گذار الگوی جوی
فصلی/زمانی	doy_sin, doy_cos, month, is_winter, is_summer	بازنمایی پیوسته چرخه سالانه
مشتق شده و تعاملی	temp_range, temp_midpoint, has_rain	کمیت‌های فیزیکی ساده و کارآمد

خانواده	نمونه ویژگی‌ها	منطق / هدف
نوسان‌پذیری و روند	temp_volatility_7d, temp_trend_7d	مومنتوم و بی‌ثباتی دما
مبتنی بر رطوبت	dew_point, temp_dewpoint_spread, rhum_lag_1	تزریق اطلاعات فیزیکی رطوبت
پرچم رویداد	extreme_temp_flag, pressure_relative	شناسایی وضعیت‌های غیرمعمول

۲-۶- اصلاحات روش شناختی انجام‌شده در فرایند مهندسی ویژگی

یکی از وجوه متمایزکننده این پروژه، رویکرد نقادانه به فرایند مهندسی ویژگی بود. در بازبینی نسخه‌های اولیه خط لوله، دو نقص مهم شناسایی شد که در ادامه شرح داده می‌شوند؛ مستندسازی این اصلاحات از آن رو اهمیت دارد که هر دو نقص، مدل را به سمت نتایج کاذب و غیرقابل تکرار سوق می‌دادند و شناسایی آن‌ها نیازمند نگاه کتی به رتبه‌بندی اهمیت ویژگی‌ها و منطق زمانی محاسبات بود.

۱-۲-۶- رفع نشی زمانی داده در ویژگی فشار نسبی

در نسخه اولیه، ویژگی «فشار نسبی» با مقایسه فشار هر روز با میانگین فشار ماه مربوطه در کل دیتاست محاسبه می‌شد؛ یعنی میانگین فشار ژانویه از داده‌های ژانویه هر شش سال (۲۰۲۰ تا ۲۰۲۵) به‌طور همزمان گرفته می‌شد. پیامد این طراحی آن بود که هنگام آموزش مدل روی داده ۲۰۲۰، این ویژگی اطلاعات میانگین فشار سال‌های ۲۰۲۴ و ۲۰۲۵ — سال‌هایی که در دنیای واقعی هنوز رخ نداده بودند — را در خود حمل می‌کرد؛ نمونه کلاسیک نشی زمانی که معیارهای ارزیابی را به‌طور غیرواقعی بالا می‌برد. نسخه اصلاح‌شده، فشار هر روز را با میانگین متحرک ۳۶۵ روزه گذشته (با یک روز تأخیر و حداقل ۱۸۰ مشاهده) مقایسه می‌کند. این محاسبه کاملاً علی است و در شرایط عملیاتی نیز دقیقاً همین‌گونه محاسبه‌پذیر است. هزینه اصلاح، حذف رکوردهای ابتدای بازه است؛ به‌گونه‌ای که نخستین نمونه قابل استفاده، ورودی ۲۹ ژوئن ۲۰۲۰ (هدف: ۳۰ ژوئن ۲۰۲۰) است. این هزینه در ازای اطمینان از اعتبار نتایج، کاملاً پذیرفتنی ارزیابی شد.

۲-۲-۶- حذف ویژگی ترکیبی بدون پایه فیزیکی

در نسخه اولیه، ویژگی حاصل ضرب مستقیم دما در فشار ($tavg \times pres$) در رتبه‌بندی اهمیت ویژگی‌ها با فاصله زیاد در صدر قرار داشت (امتیاز ۲۰/۲ در برابر حدود ۲/۵ برای ویژگی دوم). بررسی دقیق‌تر نشان داد این غلبه هیچ پایه فیزیکی ندارد: حاصل ضرب عددی حدود ۲۰ (دما) در عددی حدود ۱۰۱۳ (فشار)، مقداری در بازه هزاران تولید می‌کند که از منظر آماری عملاً نسخه بزرگ‌نمایی‌شده دمای امروز است؛ یعنی همان اطلاعات اما در مقیاسی که به‌صورت مصنوعی برجسته می‌شود. این ویژگی و مشابه آن برای باد حذف شدند و به جای آن‌ها ویژگی‌های ترکیبی معنادار فیزیکی مانند نقطه شبنم و فاصله دما تا نقطه شبنم افزوده شدند. درس روش شناختی این اصلاح آن است که «اهمیت بالا» به‌تنهایی دلیل ارزشمندی یک ویژگی نیست؛ امتیاز اهمیت باید همیشه در برابر منطق فیزیکی و مقیاس عددی ویژگی سنجیده شود.

۳-۶-۲- فعال سازی رطوبت در مدل

در بازبینی کد مشخص شد متغیر رطوبت نسبی — که هدف پروژه صریحاً آن را جزو ورودی‌ها ذکر کرده بود — در نسخه اولیه در هیچ ویژگی‌ای استفاده نمی‌شد؛ یعنی شکافی میان طرح پروژه و پیاده‌سازی وجود داشت. برای رفع این شکاف، خانواده کامل ویژگی‌های رطوبتی (بخش ۲-۵-۷) طراحی و افزوده شد. اعتبار این اقدام در نتایج نهایی نیز تأیید شد: نقطه شبینم و فاصله دما تا نقطه شبینم هر دو در میان پانزده ویژگی برتر رتبه‌بندی اهمیت نهایی قرار گرفتند.

۳-۶-۲- مدل‌های مورد مقایسه

پنج مدل یادگیری ماشین به همراه یک مدل پایه در این پژوهش مقایسه شده‌اند. انتخاب مدل‌ها به گونه‌ای انجام شده که طیف وسیعی از ساختارها — خطی، خطی با جریمه و درختی — پوشش داده شود و مقایسه منصفانه روی یک مجموعه ویژگی مشترک صورت گیرد. جدول ۲-۶ پیکربندی دقیق هر مدل را جمع‌بندی می‌کند و توضیح هر یک در ادامه آمده است.

۱-۲-۷-۲- مدل پایه تداوم

مدل پایه به صورت «دمای فردا = دمای امروز» تعریف می‌شود. همان‌گونه که در فصل اول توضیح داده شد، این مدل به دلیل اینرسی جو در افق یک‌روزه معیاری سخت‌گیرانه است و هر مدل یادگیری ماشین تنها در صورت پیشی‌گرفتن از آن توجیه‌پذیر است. معیار مدل پایه برای هر مجموعه داده به صورت مستقیم و بدون آموزش محاسبه می‌شود.

۲-۲-۷-۲- رگرسیون خطی

مدل خطی ساده‌ترین گزینه یادگیری ماشین است: $\hat{y} = w_0 + w_1x_1 + \dots + w_px_p$. این مدل به عنوان نقطه مرجع «رفتار خطی» به کار می‌رود؛ فاصله عملکرد سایر مدل‌ها با آن، برآوردی از ارزش اطلاعات غیرخطی موجود در داده است. به دلیل هم‌خطی شدید ویژگی‌های هواشناسی، رگرسیون خطی ساده به تنهایی پایدار نیست، اما مقایسه آن با Ridge اثر جریمه منقبض‌کننده را به وضوح نشان می‌دهد.

۳-۲-۷-۲- رگرسیون Ridge

رگرسیون Ridge تابع خطای مجموع مربعات را با ضریب جریمه α بر نرم L_2 بردار ضرایب جریمه می‌کند: کمینه‌سازی $\|y - Xw\|^2 + \alpha \|w\|^2$. این جریمه، واریانس برآورد ضرایب را در حضور هم‌خطی به طور چشمگیری کاهش می‌دهد. در این پژوهش $\alpha = 1/0$ استفاده شد و پیش از آموزش، تمامی ویژگی‌ها با استانداردسازی (میانگین صفر و واریانس واحد) مقیاس‌دهی شدند؛ چرا که Ridge برخلاف مدل‌های درختی به مقیاس ورودی حساس است. مدل نهایی پروژه همین Ridge است.

۲-۷-۴- جنگل تصادفی

جنگل تصادفی میانگین‌گیری از ۴۰۰ درخت رگرسیون است که هر یک روی زیرنمونه تصادفی از داده‌ها و زیرمجموعه تصادفی از ویژگی‌ها آموزش می‌بیند. پارامترهای انتخابی: حداکثر عمق ۱۰ و حداقل دو نمونه در برگ، برای مهار بیش‌برازش روی داده هواشناسی پرنویز. این مدل به مقیاس ویژگی‌ها حساس نیست و بدون استانداردسازی آموزش دید.

۲-۷-۵- تقویت گرادیان

تقویت گرادیان مدل‌های کوچک را به صورت مرحله‌ای در جهت منفی گرادیان تابع خطا اضافه می‌کند. پیکربندی این پژوهش: ۲۰۰ مرحله، نرخ یادگیری محافظه‌کارانه ۰/۰۳ و حداکثر عمق ۲ (تنه‌های بسیار ساده). نرخ یادگیری پایین با تعداد مرحله بالا، تعادل همگرایی و تعمیم‌پذیری را برقرار می‌کند و درخت‌های کم‌عمق عملاً مدل «جمع توابع تک‌متغیره و تعاملات جفتی» می‌سازند که برای داده هواشناسی انتخابی مقاوم است.

۲-۷-۶- XGBoost

XGBoost پیاده‌سازی بهینه‌شده تقویت گرادیان با جریمه پیچیدگی درخت، نمونه‌گیری سطر و ستون و موازی‌سازی است. پیکربندی: ۳۰۰ درخت، نرخ یادگیری ۰/۰۳، حداکثر عمق ۳، subsample برابر ۰/۸ و colsample_bytree برابر ۰/۹. نمونه‌گیری سطر و ستون تنوع درخت‌ها را افزایش داده و از بیش‌برازش می‌کاهد؛ تابع هدف، خطای مربعات رگرسیونی است.

جدول ۲-۶: پیکربندی مدل‌های مورد مقایسه

مدل	ابریارامترها	پیش‌پردازش
مدل پایه (تداوم)	بدون آموزش	—
رگرسیون خطی	پیش‌فرض	استانداردسازی
Ridge	$\alpha = 1/0$	استانداردسازی
جنگل تصادفی	n=۴۰۰، عمق=۱۰، حداقل برگ=۲، seed=۴۲	بدون نیاز
تقویت گرادیان	n=۲۰۰، نرخ یادگیری=۰/۰۳، عمق=۲، seed=۴۲	بدون نیاز
XGBoost	n=۳۰۰، نرخ یادگیری=۰/۰۳، عمق=۳، subsample=۰/۸، colsample=۰/۹، seed=۴۲	بدون نیاز

نکته پیاده‌سازی مهم آن است که برای دو مدل خطی از خط لوله Pipeline شامل استانداردسازی استفاده شد و هر سه مدل درختی بدون استانداردسازی آموزش دیدند؛ به این ترتیب مقایسه میان مدل‌ها منصفانه است و تفاوت عملکرد بازتاب ساختار مدل است، نه تفاوت پیش‌پردازش.

۲-۸ - تقسیم زمانی داده

با توجه به ماهیت سری زمانی مسئله، تقسیم تصادفی داده مطلقاً ممنوع است: تقسیم تصادفی، نمونه‌های همسایه زمانی را دو سمت مرز آموزش و آزمون می‌فرستد و عملاً به مدل اجازه می‌دهد پاسخ آزمون را از نمونه‌های تقریباً یکسان مجاورش حفظ کند. به همین دلیل تقسیم کاملاً مبتنی بر بازه زمانی استفاده شد (جدول ۲-۷): ابتدا مدل‌های نامزد روی سال‌های ۲۰۲۰ تا ۲۰۲۳ آموزش می‌بینند و روی سال ۲۰۲۴ اعتبارسنجی می‌شوند؛ پس از انتخاب مدل برتر، مدل نهایی روی کل داده ۲۰۲۰ تا پایان ۲۰۲۴ آموزش مجدد می‌بیند تا از حداکثر داده تاریخی بهره‌بردارد؛ و ارزیابی نهایی صرفاً روی سال ۲۰۲۵ — بازه‌ای که مدل در هیچ مرحله‌ای ندیده — انجام می‌شود.

جدول ۲-۷: تقسیم زمانی داده‌ها

مجموعه	بازه زمانی	نقش	حجم تقریبی
آموزش اولیه	۲۰۲۰-۰۱-۰۱ تا ۲۰۲۳-۱۲-۳۱	آموزش مدل‌های نامزد	۱۲۸۱ نمونه
اعتبارسنجی	۲۰۲۴-۰۱-۰۱ تا ۲۰۲۴-۱۲-۳۰	انتخاب بهترین مدل	۳۶۵ نمونه
آموزش نهایی	۲۰۲۰-۰۱-۰۱ تا ۲۰۲۴-۱۲-۳۰	آموزش مجدد بهترین مدل	۱۶۴۶ نمونه
آزمون نهایی	۲۰۲۵-۰۱-۰۱ تا ۲۰۲۵-۱۲-۳۱	ارزیابی نهایی و بی‌طرفانه	۳۶۵ نمونه

در پی اصلاح ویژگی فشار نسبی (بخش ۲-۱-۶)، رکوردهای ابتدایی که پنجره یک‌ساله گذشته ندارند حذف شدند؛ نخستین رکورد ورودی قابل استفاده مربوط به ۲۹ ژوئن ۲۰۲۰ است و متغیر هدف آن، میانگین دمای ۳۰ ژوئن ۲۰۲۰ است. یادآوری می‌شود ورودی روز ۳۰ دسامبر ۲۰۲۴، هدف ۳۱ دسامبر ۲۰۲۴ را پیش‌بینی می‌کند و از ۱ ژانویه ۲۰۲۵، مدل صرفاً در حالت آزمون قرار دارد.

۲-۹ - معیارهای ارزیابی و ابزارهای تحلیل

دو معیار استاندارد رگرسیون برای ارزیابی استفاده شد. خطای میانگین مطلق (MAE) برابر میانگین قدرمطلق خطاهاست:

$$MAE = \frac{1}{n} \sum |y_i - \hat{y}_i|$$

این معیار به دلیل هم‌مقیاس بودن با متغیر هدف (درجه سانتی‌گراد) و مقاومت در برابر داده پرت، معیار اصلی گزارش است و تفسیر عملیاتی مستقیمی دارد: «میانگین خطای پیش‌بینی روزانه چند درجه است». خطای جذر میانگین مربعات (RMSE) برابر جذر میانگین مربع خطاهاست: $RMSE = \sqrt{\frac{1}{n} \sum (y_i - \hat{y}_i)^2}$ ؛ وزن دهی درجه دو به خطاهای بزرگ، آن را به مکمل ارزشمندی تبدیل می‌کند: اختلاف زیاد RMSE و MAE نشانه وجود روزهای پرخطاست.

برای سنجش بهبود نسبت به مرجع، امتیاز مهارت به صورت $1 - (MAE / \text{مدل پایه})$ محاسبه می‌شود که عددی صفر به معنای هم‌ارزی با تداوم و عدد مثبت به معنای برتری از آن است. علاوه بر این معیارها، سه ابزار تحلیلی مکمل استفاده شد: رتبه‌بندی اهمیت ویژگی‌ها با روش جای چینی^{۱۳}

^{۱۳} پیاده‌سازی استفاده‌شده در scikit-learn مستند است در: Pedregosa, F., et al. (۲۰۱۱). Scikit-learn: Machine learning in Python. JMLR, ۱۲, ۲۸۲۵-۲۸۳۰.

در این روش مقادیر هر ویژگی به صورت تصادفی در هم می‌شوند و افت معیار عملکرد مدل روی داده آزمون اندازه‌گیری می‌شود؛ افت زیاد به معنای وابستگی زیاد مدل به آن ویژگی است. مزیت این روش بر اهمیت ذاتی مدل‌های درختی، یکسان بودن رویه برای همه مدل‌ها و سنجش اهمیت در سطح تعامل مدل و داده آزمون واقعی است. در این پژوهش معیار درون روش منفی MAE، تعداد تکرار ۲۰ بار برای کنترل واریانس برآورد و seed ثابت ۴۲ برای تکرارپذیری انتخاب شد. دو ابزار دیگر، تفکیک خطا بر حسب ماه سال و جهت خطا (بیش برآورد در برابر کم‌برآورد) و تحلیل موردی روزهای پرخفا با مرور شرایط جوی روزهای همسایه است؛ این ابزارها به‌طور مشترک به پرسش «مدل کجا و چرا خطا می‌کند» پاسخ می‌دهند.

۲-۱۰- ابزارهای پیاده‌سازی و ساختار نرم‌افزاری

تمامی پیاده‌سازی‌ها در زبان پایتون انجام شده است. کتابخانه‌های اصلی: pandas برای ساختاردهی و پردازش داده جدولی؛ numpy برای محاسبات عددی؛ scikit-learn برای مدل‌های رگرسیون، خط لوله، معیارها و اهمیت جای چینی؛ XGBoost برای مدل متناظر؛ matplotlib برای تولید نمودارها؛ و joblib برای ذخیره مدل نهایی و فهرست ویژگی‌ها جهت استفاده در مازول پیش‌بینی تعاملی. جدول ۸-۲ نقش مازول‌های نرم‌افزاری پروژه را جمع‌بندی می‌کند؛ کل چرخه از دریافت داده تا خروجی نهایی با اجرای متوالی پنج اسکریپت به صورت خودکار و تکرارپذیر قابل اجراست و هیچ گام دستی دخالتی در نتایج ندارد.

جدول ۸-۲: مازول‌های نرم‌افزاری پروژه و نقش هریک

ماژول	نقش
config.py	مسیرها، نام ستون‌ها و مرزهای زمانی داده
download_data.py	دریافت خودکار داده از Open-Meteo
data_loader.py	بارگذاری، مرتب‌سازی و پاک‌سازی داده
feature_engineering.py	منطق ساخت ۴۶ ویژگی در یک تابع مستند
train_temperature_model.py	آموزش، انتخاب مدل، ارزیابی و خروجی‌ها
predict_for_date.py	رابط تعاملی پیش‌بینی برای تاریخ دلخواه
analyze_errors.py	تحلیل روزهای پرخفا و مقایسه مدل‌ها
monthly_mae.py	تحلیل ماهانه خطا و تولید جدول و نمودار ماهانه

فصل سوم: آزمایش‌ها و ارزیابی‌ها

۳-۱- سناریوی آزمایش

سناریوی آزمایش به دو مرحله متوالی سازمان یافته است. در مرحله نخست (اعتبارسنجی)، پنج مدل نامزد روی داده آموزش ۲۰۲۰ تا ۲۰۲۳ آموزش می‌بینند و عملکردشان روی سال کامل ۲۰۲۴ (۳۶۵ روز پیش‌بینی یک‌روزه) با معیارهای MAE و RMSE سنجیده می‌شود؛ مدل تداوم نیز روی همان بازه ارزیابی می‌شود تا سنجش مرجع برقرار باشد. در مرحله دوم (آزمون نهایی)، مدل برتر پس از آموزش مجدد روی ۲۰۲۰ تا ۲۰۲۴، برای تمام ۳۶۵ روز سال ۲۰۲۵ پیش‌بینی یک‌روزه تولید می‌کند و نتایج با مقادیر واقعی مقایسه می‌شود. چنین طراحی دو مرحله‌ای تضمین می‌کند داده آزمون ۲۰۲۵ در هیچ تصمیمی — نه انتخاب مدل و نه تنظیم ابرپارامترها — دخالت ندارد و برآورد نهایی، بی‌طرفانه باشد.


علاوه بر این دو سناریوی اصلی، سه تحلیل تکمیلی طراحی شده است: رتبه‌بندی اهمیت ویژگی‌ها با روش جای چینی روی داده آزمون، تفکیک خطا بر حسب ماه سال و جهت خطا برای شناسایی الگوهای فصلی و سوگیری مدل، و تحلیل موردی روزهای پرخطا (روزهایی که خطای مدل از میانگین خودش فراتر رفته) با مقایسه عملکرد همه مدل‌ها در آن روزها. این سه تحلیل، بخش عمده فهم کیفی رفتار مدل را فراهم کرده‌اند. برای تکرارپذیری کامل، همه آزمایش‌ها با seed ثابت ۴۲ اجرا شده‌اند و خروجی‌های عددی و نموداری هر اجرا در پوشه outputs ذخیره می‌شود.

۳-۲- نتایج اعتبارسنجی (سال ۲۰۲۴)

جدول ۱-۳ نتایج مرحله اعتبارسنجی را نشان می‌دهد. مدل Ridge با خطای میانگین مطلق ۱/۰۲۱ درجه سانتی‌گراد بهترین عملکرد را داشت و رگرسیون خطی با اختلاف اندک (۰/۰۰۴ درجه) در رتبه دوم قرار گرفت؛ این رتبه‌بندی تنگاتنگ نشان می‌دهد عمده قدرت پیش‌بینی در ساختار خطی رابطه نهفته است و جریمه L۲ تنها پایداری ضرایب را بهبود می‌دهد. هر سه مدل درختی — جنگل تصادفی، تقویت‌گرادیان و XGBoost — در فاصله ۴ تا ۱۰ صدم درجه پایین‌تر از مدل‌های خطی قرار گرفتند که با توجه به نویز ذاتی داده روزانه هواشناسی، اختلافی معنادار اما نه تعیین‌کننده است.

جدول ۱-۳: نتایج اعتبارسنجی مدل‌های نامزد روی سال ۲۰۲۴ (مرتب بر اساس MAE)

مدل	MAE (درجه سانتی‌گراد)	RMSE (درجه سانتی‌گراد)
Ridge	۱/۰۲۱	۱/۳۵۴
رگرسیون خطی	۱/۰۲۵	۱/۳۵۸
XGBoost	۱/۰۶۴	۱/۴۱۵
جنگل تصادفی	۱/۰۹۱	۱/۴۸۰
تقویت‌گرادیان	۱/۱۷	۱/۴۸۱
مدل پایه (تداوم)	۱/۲۱۷	۱/۶۱۱



شکل ۱-۳: مقایسه معیارهای MAE و RMSE مدل‌های نامزد روی داده اعتبارسنجی سال ۲۰۲۴

سه مشاهده از این جدول قابل استخراج است. نخست، همه پنج مدل یادگیری ماشین از مدل تداوم بهتر عمل کرده‌اند؛ این یعنی افزودن ویژگی‌های مهندسی‌شده، اطلاعات واقعی و مازاد بر «دمای امروز» در اختیار مدل‌ها قرار داده است. دوم، نسبت RMSE به MAE برای همه مدل‌ها حدود ۱٫۳۳ است که نشان می‌دهد توزیع خطاها نسبتاً یکنواخت است و دنباله سنگینی از خطاهای فاجعه‌بار وجود ندارد. سوم، برتری مدل‌های خطی بر مدل‌های درختی در این مسئله با ادبیات سازگار است: هنگامی که رابطه اصلی (تداوم دمایی همراه با اصلاح فصلی) ذاتاً نزدیک به خطی است، مدل‌های درختی که روابط پله‌ای می‌سازند مزیت چندانی از غیرخطی بودن نمی‌گیرند و به دلیل ناتوانی نسبی در برون‌یابی، در ماه‌های مرزی فصل‌ها عملکردی هموارتر اما کمتر دقیق دارند.


۳-۳- انتخاب مدل نهایی و آموزش مجدد

بر اساس نتایج اعتبارسنجی، مدل Ridge به عنوان مدل نهایی انتخاب شد. مراحل پس از انتخاب عبارت بودند از: آموزش مجدد مدل روی کل بازه ۲۰۲۰ تا پایان ۲۰۲۴ تا تجربه داده اعتبارسنجی نیز در پارامترهای نهایی لحاظ شود، ذخیره مدل به همراه فهرست دقیق ویژگی‌ها در قالب فایل‌های joblib برای استفاده مجدد در مائول پیش‌بینی تعاملی، و تولید پیش‌بینی‌های نهایی روی سال ۲۰۲۵. انتخاب مدل «فقط» بر داده اعتبارسنجی انجام شد و داده آزمون تا پیش از ارزیابی نهایی هیچ نقشی نداشت؛ این نکته، بی‌طرفانه بودن برآورد عملکرد نهایی را تضمین می‌کند.

۳-۴- نتایج آزمون نهایی (سال ۲۰۲۵)

جدول ۲-۳: نتایج آزمون نهایی روی سال ۲۰۲۵

معیار	مدل پایه (تداوم)	Ridge (مدل نهایی)	بهبود
MAE (درجه سانتی‌گراد)	۱٫۱۹۶	۱٫۰۰۵	۱۵٫۹۵٪
RMSE (درجه سانتی‌گراد)	۱٫۵۷۹	۱٫۲۷۶	۱۹٫۱۹٪



شکل ۲-۳: مقایسه دمای واقعی و پیش‌بینی‌شده روی داده آزمون سال ۲۰۲۵ (مدل Ridge)

مدل نهایی روی ۳۶۵ روز سال ۲۰۲۵ به خطای میانگین مطلق ۱/۰۰۵ و خطای جذر میانگین مربعات ۱/۲۷۶ درجه سانتی‌گراد رسید که به‌ترتیب ۱۵/۹۵ و ۱۹/۱۹ درصد بهتر از مدل تداوم است (شکل ۲-۳)؛ به بیان امتیاز مهارت، مدل ۱۶ درصد تابع خطای مرجع را کاهش داده است. نکته مهم روش‌شناختی آن است که این اعداد پس از رفع نشتی داده و حذف ویژگی مصنوعی به دست آمده‌اند؛ در نسخه اولیه خط لوله (با نقص‌های بخش ۲-۶) عدد بهبود به‌صورت کاذب بالاتر نشان داده می‌شد. بنابراین رقم ۱۵/۹۵ درصد برآوردی محافظه‌کارانه اما قابل‌اتکا از ارزش افزوده مدل است.

بهبود بزرگ‌تر در معیار RMSE نسبت به MAE (۱۹/۲ در برابر ۱۶/۰ درصد) اهمیت تحلیلی دارد: این اختلاف نشان می‌دهد مدل به‌ویژه در همان روزهایی که خطای مدل پایه بزرگ است، عملکرد بهتری دارد؛ یعنی مدل موفق شده بخشی از اطلاعات ساختاری (فصلی، فشاری و رطوبتی) را که تداوم از آن بی‌بهره است به پیش‌بینی اضافه کند. میانگین خطای مطلق حدود یک درجه سانتی‌گراد برای پیش‌بینی یک‌روزه تنها با مشاهدات زمینی، عملکردی است که برای کاربردهای عملیاتی مانند برنامه‌ریزی انرژی و کشاورزی کاملاً کاربردپذیر است.


۱-۴-۳- تفکیک ماهانه خطا

برای بررسی الگوی فصلی خطاها، خطای روزانه مدل بر اساس ماه تقویمی روز هدف گروه‌بندی و میانگین شد (پیاده‌سازی در ماژول monthly_mae.py). جدول ۳-۳ و شکل ۳-۳ خطای میانگین مطلق مدل را بر حسب ماه سال آزمون نشان می‌دهند. کمترین خطا در اوت (۰/۵۹)، اکتبر (۰/۶۱) و ژانویه (۰/۸۱) رخ داده است؛ ماه‌هایی که الگوی جوی پایدار دارد و رویدادهای گذار ندارند. بیشترین خطا در آوریل (۱/۶۰)، ژوئن (۱/۲۸) و فوریه (۱/۲۳) ثبت شده است — الگویی که با انتظار نظری سازگار است: ماه‌های گذار فصلی (بهار و اواخر زمستان) به دلیل جابه‌جایی سریع توده‌های هوای سرد و گرم بیشترین نوسان‌پذیری را دارند و به همین دلیل حتی برای مدل‌های عملیاتی پیش‌بینی هوا نیز دشوارترین دوره سال‌اند.

جدول ۳-۳: خطای میانگین مطلق ماهانه مدل Ridge در سال ۲۰۲۵ (ماه‌ها به تقویم میلادی)

ماه میلادی	معادل تقریبی شمسی	MAE (درجه سانتی‌گراد)
ژانویه	دی	۰/۸۱
فوریه	بهمن	۱/۲۳
مارس	اسفند	۱/۰۷

ماه میلادی	معادل تقریبی شمسی	MAE (درجه سانتی‌گراد)
آوریل	فروردین	۱٫۶۰
مه	اردیبهشت	۱٫۰۵
ژوئن	خرداد	۱٫۲۸
ژوئیه	تیر	۱٫۰۹
اوت	مرداد	۰٫۵۹
سپتامبر	شهریور	۰٫۸۲
اکتبر	مهر	۰٫۶۱
نوامبر	آبان	۱٫۰۵
دسامبر	آذر	۰٫۹۰



شکل ۳-۳: خطای میانگین مطلق ماهانه مدل Ridge در سال آزمون ۲۰۲۵

۳-۴-۲- جهت خطا و سوگیری مدل


بررسی جهت خطا نشان می‌دهد توزیع بیش‌برآورد (۴۷/۹ درصد روزها) و کم‌برآورد (۵۲/۱ درصد روزها) تقریباً متوازن است؛ یعنی مدل سوگیری سیستماتیک کلی ندارد. این توازن پیامد مستقیم ساختار خطی مدل و استانداردسازی ویژگی‌هاست و از منظر کاربردی مهم است: مدل‌های دارای سوگیری یک‌طرفه در کاربردهای انرژی و کشاورزی نیاز به اصلاح پس‌پردازشی سوگیری دارند، اما خروجی این مدل بدون چنین اصلاحی قابل استفاده است.

۳-۵- اهمیت ویژگی‌ها

جدول ۴-۳ پانزده ویژگی برتر بر اساس اهمیت جای‌چینی روی داده آزمون ۲۰۲۵ را نشان می‌دهد. سه ویژگی نخست — موقعیت کسینومی در چرخه سالانه (doy_cos با امتیاز ۱/۰۰۰)، دمای امروز (avg با ۰/۷۷۰) و میانگین ۳۰ روزه دما (۰/۶۷۴) — با فاصله معنادار از بقیه پیش‌تازند؛ این سه‌گانه دقیقاً بازتاب دانش هواشناسی است: دمای فردا در گام نخست تابع موقعیت در فصل، سطح فعلی دما و میانگین بلندمدت آن است.

جدول ۴-۳: پانزده ویژگی برتر بر اساس اهمیت جای چینی (مدل Ridge، داده آزمون ۲۰۲۵)

رتبه	ویژگی	شرح	امتیاز اهمیت
۱	doy_cos	موقعیت در چرخه فصلی	۱/۰۰۰
۲	tavg	دمای میانگین امروز	۰/۷۷۰
۳	tavg_roll_30_mean	میانگین ۳۰ روزه دما	۰/۶۷۴
۴	tavg_lag_1	دمای دیروز	۰/۶۳۶
۵	tavg_roll_7_mean	میانگین ۷ روزه دما	۰/۶۲۹
۶	tavg_lag_3	دمای سه روز قبل	۰/۶۰۹
۷	pres	فشار امروز	۰/۵۰۳
۸	temp_dewpoint_spread	فاصله دما تا نقطه شبنم	۰/۴۹۷
۹	tavg_change_1d	تغییر یکروزه دما	۰/۴۶۳
۱۰	tavg_roll_3_mean	میانگین ۳ روزه دما	۰/۴۴۷
۱۱	dew_point	نقطه شبنم	۰/۴۲۲
۱۲	pressure_relative	فشار نسبی (علی)	۰/۳۴۲
۱۳	temp_range_rain_interaction	تعامل دامنه دما و بارش	۰/۳۱۳
۱۴	has_rain	پرچم بارش	۰/۲۳۱
۱۵	tavg_change_3d	تغییر سهروزه دما	۰/۲۲۲



شکل ۴-۳: نمودار اهمیت ویژگی‌ها با روش جای چینی (مدل Ridge، داده آزمون ۲۰۲۵)

سه نکته از این رتبه‌بندی استخراج می‌شود. نخست، رتبه‌بندی منطق‌مند است: برخلاف نسخه اولیه که ویژگی مصنوعی $tavg \times pres$ با امتیاز ۲۰/۲ بر نتایج مسلط بود، اکنون هیچ ویژگی‌ای به‌طور غیرطبیعی برتر نیست و سقف امتیاز در حد تناوب فصلی است که واقعاً مهم‌ترین عامل دمای فرداست. دوم، حضور هر دو ویژگی رطوبتی جدید (فاصله دما تا نقطه شبنم در رتبه ۸ و نقطه شبنم در رتبه ۱۱) در میان پانزده ویژگی برتر، ارزش افزوده فعال‌سازی رطوبت را به‌صورت کفی تأیید می‌کند. سوم، ویژگی فشار نسبی اصلاح‌شده (رتبه ۱۲) همچنان اطلاعات مؤثری حمل می‌کند؛ این در حالی است که نسخه نشی‌دار آن به دلیل دسترسی غیرمجاز به آینده اهمیت کاذب بسیار بالاتری نشان می‌داد و همین تفاوت، گواه عملی ضرورت اصلاح بود.

۳-۶- تحلیل روزهای پرخطا

برای شناسایی نقاط ضعف مدل، همه روزهای سال آزمون که خطای مدل Ridge در آن‌ها از میانگین خودش (۱/۰۰۵ درجه) بیشتر بود استخراج شدند؛ تعداد این روزها ۱۴۸ روز (۴۰/۵ درصد سال) است. برای هر یک از این روزها پیش‌بینی هر شش مدل (پایه تا XGBoost) مقایسه شد تا مشخص گردد آیا خطای مدل خطی، مشکل ساختاری «همه مدل‌ها» است یا ضعف خاص مدل انتخابی. جدول ۳-۵ ده روز با بیشترین خطای مطلق را نشان می‌دهد.

جدول ۳-۵: ده روز با بیشترین خطای مطلق مدل Ridge در سال ۲۰۲۵

تاریخ هدف	دمای واقعی (C°)	پیش‌بینی پایه	پیش‌بینی Ridge	خطای Ridge	بهترین مدل آن روز
۱۶ آوریل	۱۵/۴	۲۱/۶	۲۰/۴	۴/۹۶	Ridge
۴ ژوئن	۲۵/۰	۳۱/۱	۲۹/۶	۴/۶۴	رگرسیون خطی
۹ فوریه	-۰/۱	۳/۲	۴/۳	۴/۴۱	مدل پایه
۲۹ آوریل	۲۱/۵	۲۶/۰	۲۵/۶	۴/۰۸	XGBoost
۶ ژوئیه	۳۰/۴	۳۲/۳	۳۳/۹	۳/۴۶	مدل پایه
۷ فوریه	۴/۳	۹/۶	۷/۷	۳/۴۰	XGBoost
۶ آوریل	۱۷/۴	۱۵/۳	۱۴/۰	۳/۳۷	مدل پایه
۲۵ فوریه	-۱/۴	۳/۰	۲/۰	۳/۳۶	Ridge
۲۷ ژانویه	۴/۱	۷/۰	۷/۱	۳/۰۵	XGBoost
۲۶ فوریه	۱/۲	-۱/۴	-۱/۷	۲/۹۰	XGBoost

سه الگوی مهم در این تحلیل آشکار می‌شود. نخست، غلبه روزهای گذار فصلی: از ده روز پرخطا، شش روز در فوریه تا آوریل قرار دارند و بقیه نیز به رویدادهای گذاری خاص (مانند سقوط دمای ۴ ژوئن) مربوط‌اند. دوم، جهت خطا: در اغلب این روزها مدل دما را بیش از واقعیت برآورد کرده و در بخش بزرگی از آن‌ها سقوط ناگهانی دما رخ داده بود (برای نمونه، در ۱۶ آوریل دما از حدود ۲۰ درجه به ۱۵/۴ درجه سقوط کرد و در ۴ ژوئن از ۳۱ به ۲۵ درجه). مدل — و تقریباً همه مدل‌های مشاهداتی — تمایل دارند دمای پایدار را ادامه دهند و شدت سقوط‌های ناگهانی را کم‌برآورد کنند. سوم و مهم‌تر، در ۵۵ روز از ۱۴۸ روز پرخطا (۳۷ درصد)، حتی مدل ساده تداوم بهتر از همه مدل‌های یادگیری ماشین عمل کرده است؛ این آمار به‌روشنی نشان می‌دهد که خطاهای بزرگ، مشکل

«هیچ‌کدام از مدل‌های مبتنی بر مشاهدات گذشته» نیست، بلکه ماهیت رویدادهاست: در تغییرات ناگهانی جو، هیچ تابعی از گذشته نمی‌تواند تحول آینده را پیش‌بینی کند و تنها داده‌های سه‌بعدی جو (که در مدل‌های عددی در دسترس است) می‌تواند چنین رویدادهایی را رصد کند.

تحلیل موردی سه روز پرخطای نخست با مرور شرایط جوّی روزهای همسایه نیز همین جمع‌بندی را تأیید کرد: در هر سه مورد، تغییر سریع فشار و جهش یا سقوط شدید دما در روز هدف وجود داشته و در روزهای قبل، نشانه‌های متعارف گذار (افت فشار، تغییر باد) فقط به‌صورت ناقص ثبت شده بود. توصیه عملیاتی حاصل از این تحلیل در بخش کارهای آینده (فصل چهارم) تبیین شده است.

۳-۷- بحث و جمع‌بندی نتایج

نتایج فصل حاضر را می‌توان در چهار گزاره جمع کرد. نخست، مهندسی ویژگی دقیق و علی، حتی با یک مدل خطی ساده، می‌تواند دقت پیش‌بینی یک‌روزه دما را حدود ۱۶ درصد بهتر از مدل تداوم برساند؛ این نتیجه ادعای محوری پروژه را تأیید می‌کند. دوم، برتری مدل خطی Ridge بر مدل‌های درختی در این مسئله یادآور آن است که پیچیدگی الگوریتم باید با ماهیت مسئله هم‌خوان باشد؛ در مسئله‌ای که رابطه اصلی آن نزدیک خطی است، مدل‌های پیچیده صرفاً نویز بیشتری مدل می‌کنند. سوم، رتبه‌بندی اهمیت ویژگی‌ها پس از اصلاحات روش‌شناختی با دانش هواشناسی هم‌راستا شده است — گواهی که اعتبار فرایند مهندسی ویژگی را مستند می‌کند. چهارم، تحلیل خطاها نشان داد محدودیت اصلی این خانواده از مدل‌ها در رویدادهای ناگهانی و گذار فصلی است؛ محدودیتی ساختاری که با تغییر الگوریتم رفع نمی‌شود و نیازمند افزودن منابع اطلاعاتی جدید است.

از منظر اعتبار درونی نتایج، سه لایه محافظت به کار رفته است: تقسیم کاملاً زمانی داده، علی‌بودن تمامی ویژگی‌ها و عدم استفاده از داده آزمون در هر تصمیم‌گیری. بر این اساس، ارقام گزارش‌شده در این فصل برآوردی بی‌طرفانه از عملکردی است که مدل در استقرار واقعی (پیش‌بینی فردا با مشاهدات امروز) از خود نشان خواهد داد.

فصل چهارم: نتیجه‌گیری و کارهای آینده

۴-۱- جمع‌بندی دستاوردها

این پروژه نشان داد که ترکیب مهندسی ویژگی دقیق و علی با یک مدل خطی منقبض شده (رگرسیون Ridge) می‌تواند برای پیش‌بینی دمای میانگین روز آینده در تهران عملکردی قابل اتکا و کاملاً تفسیرپذیر ارائه دهد: خطای میانگین مطلق ۱/۰۰۵ درجه سانتی‌گراد روی سال آزمون ۲۰۲۵، معادل بهبود ۱۵/۹۵ درصدی نسبت به مدل تداوم در MAE و ۱۹/۱۹ درصدی در RMSE. مهم‌تر از انتخاب الگوریتم، کیفیت روش شناختی چرخه داده بود: سه لایه محافظت (تقسیم زمانی داده، علی‌بودن همه ویژگی‌ها و بی‌توجهی کامل به داده آزمون در تصمیم‌گیری‌ها) به همراه اصلاح دو نقص شناسایی شده (نشتی زمانی در ویژگی فشار نسبی و حذف ویژگی ترکیبی بدون پایه فیزیکی) به مدلی انجامید که نتایجش قابل دفاع است و رفتار آن با دانش هواشناسی سازگار است.

دستآورد دوم، چارچوب مقایسه نظام‌مند پنج خانواده مدل روی مجموعه ویژگی مشترک بود که نشان داد در این مسئله مدل‌های خطی با جریمه از مدل‌های درختی پیشی می‌گیرند؛ یافته‌ای که در ادبیات کمتر صریح گزارش می‌شود اما با ماهیت نزدیک به خطی رابطه تداوم دمایی سازگار است. دستآورد سوم، فعال‌سازی متغیر رطوبت از طریق چهار ویژگی فیزیکی معنادار بود که هر دو کمیت اصلی آن (نقطه شبنم و فاصله دما تا شبنم) در میان ویژگی‌های برتر نهایی قرار گرفتند. دستآورد چهارم، تحلیل تفصیلی خطاهاست که مرزهای کاربرد مدل را به صورت کمی ترسیم کرد: عملکرد عالی در ماه‌های پایدار (اوت، اکتبر)، افت محسوس در ماه‌های گذار (آوریل، ژوئن، فوریه) و عدم توان پیش‌بینی رویدادهای ناگهانی — که برای همه مدل‌های مبتنی بر مشاهدات گذشته مشترک است.

۴-۲- محدودیت‌ها

محدودیت‌های این پژوهش را می‌توان در پنج محور برشمرد:

- ۱. داده سرعت باد منبع بازتحلیل ERA۵ همبستگی نسبتاً ضعیفی (۰/۶۱۴) با مشاهدات ایستگاهی دارد؛ وضوح مکانی حدود ۹ تا ۲۵ کیلومتری بازتحلیل، اثرات محلی محوطه فرودگاه را ثبت نمی‌کند و بنابراین اطلاعاتی که مدل از ویژگی‌های بادی دریافت می‌کند کم‌کیفیت‌تر از بقیه است.
- ۲. مدل صرفاً بر مبنای مشاهدات روز جاری و گذشته عمل می‌کند و به داده‌های سه‌بعدی جو دسترسی ندارد؛ بنابراین جایگزین مدل‌های عددی پیش‌بینی جو نیست و در رویدادهای ناگهانی (سقوط یا جهش سریع دما همراه تغییر فشار) خطای آن به‌طور محسوس افزایش می‌یابد. تحلیل ۱۴۸ روز پرخطا نشان داد حتی مدل ساده تداوم در بیش از یک‌سوم این روزها بهتر از همه مدل‌های یادگیری ماشین عمل می‌کند؛ گواهی ساختاری بر این محدودیت.
- ۳. مدل صرفاً برای نقطه جغرافیایی تهران (مهرآباد) آموزش دیده است و تعمیم آن به شهرها یا اقلیم‌های دیگر بدون آموزش مجدد توصیه نمی‌شود؛ ساختار فصلی، دامنه دمایی و پیش‌نشانگرهای جوی یادگرفته شده خاص همین نقطه‌اند.
- ۴. افق پیش‌بینی صرفاً یک روز است. توسعه به افق‌های چندروزه (۲ تا ۷ روز) نیازمند بازطراحی تعریف هدف و ویژگی‌هاست و خطا در افق‌های بلندتر به سرعت رشد می‌کند.

- ۵. پنجره داده (شش سال) ممکن است تمامی تنوع اقلیمی — از جمله سال‌های گرمایی استثنایی — را پوشش ندهد؛ رفتار مدل در شرایطی فراتر از دامنه مشاهده شده (مانند موج گرمای بی‌سابقه) تضمینی ندارد.

۴-۳- پیشنهادهایی برای کارهای آینده

بر پایه یافته‌ها و محدودیت‌های بالا، مسیرهای توسعه آینده به سه دسته تقسیم می‌شوند:

۴-۳-۱- گسترش ویژگی‌ها

- افزودن هارمونیک دوم فوریه (سینوسی/کسینوسی با دوره نصف سال) برای ثبت عدم تقارن ساختار بهار و پاییز؛ در داده تهران شیب گرم شدن بهار با شیب سرد شدن پاییز متفاوت است و هارمونیک دوم این تفاوت را ثبت می‌کند.
- ساخت ویژگی‌های تأخیری مستقل بیشتر برای دمای کمینه و بیشینه برای ثبت پایداری یخبندان‌ها و موج‌های گرما به صورت صریح.
- استفاده از میانگین متحرک نمایی (EWMA) به جای میانگین ساده، تا روزهای اخیر وزن بیشتری بگیرند و واکنش مدل به گذارهای جوی سریع‌تر شود.
- افزودن متغیرهای در دسترس اما استفاده نشده منبع داده، مانند ساعات آفتابی، برف و تندباد؛ ساعات آفتابی به‌ویژه پیش‌نشانگر پوشش ابر و در نتیجه دامنه دمایی روز بعد است.

۴-۳-۲- گسترش مدل‌سازی

- تلفیق خروجی مدل‌های عددی پیش‌بینی جو (مانند دمای پیش‌بینی شده GFS یا ECMWF برای فردا) به عنوان ویژگی ورودی؛ این پس‌پردازش دقیقاً همان جایی است که تحلیل خطاها ضعف مدل را نشان داد و در ادبیات مؤثرترین مسیر بهبود شناخته می‌شود.
- افزودن مدل‌های سری زمانی تخصصی (SARIMA) و شبکه‌های بازگشتی (LSTM) به مقایسه، برای سنجش ارزش مدل‌سازی صریح ساختار زمانی در برابر بازنمایی ویژگی محور فعلی.
- به کارگیری اعتبارسنجی متوالی (Walk-forward) به جای اعتبارسنجی تک‌بازه‌ای، برای برآورد پایداری عملکرد در طول زمان.
- بهینه‌سازی ابرپارامترها (به‌ویژه α در Ridge و ساختار درخت‌ها) با جست‌وجوی شبکه‌ای زمانی، به جای مقادیر پیش‌فرض.

۴-۳-۳- گسترش کاربردی

- تعمیم خط لوله به سایر شهرهای ایران (شیراز، اهواز، تبریز) و مطالعه تطبیقی اهمیت ویژگی‌ها در اقلیم‌های متفاوت؛ برای نمونه انتظار می‌رود سهم ویژگی‌های رطوبتی در اهواز مرطوب‌تر به مراتب بیشتر باشد.
- توسعه پیش‌بینی احتمالاتی: افزودن بازه عدم قطعیت (برای نمونه با رگرسیون کوآنتیلی) به خروجی مدل، به‌ویژه برای روزهای پرنوسان که رتبه‌بندی اطمینان باید متفاوت باشد.
- استقرار عملیاتی: ساخت سرویس روزانه‌ای که مشاهدات امروز را دریافت، ویژگی‌ها را محاسبه و پیش‌بینی فردا را با بازه عدم قطعیت گزارش کند؛ زیرساخت مدل و ویژگی‌ها (فایل‌های joblib) از قبل برای این استقرار آماده است.

۴-۴- سخن پایانی

جمع‌بندی نهایی این پژوهش را می‌توان در یک جمله فشرد: در پیش‌بینی کوتاه‌مدت دما با داده‌های زمینی، دقت نهایی بیشتر از آن‌که محصول انتخاب الگوریتم باشد، محصول انضباط روش‌شناختی در کل چرخه داده است. تجربه این پروژه — از کشف نشی زمانی تا حذف ویژگی‌های فریبنده‌ای که با امتیاز اهمیت هشت‌برابری در صدر می‌درخشید — نشان داد که اعتبارسنجی نقادانه فرایند، به همان اندازه طراحی ویژگی‌های جدید ارزش‌آفرین است. امید است مستندسازی کامل این چارچوب و اصلاحات آن، برای پژوهش‌های بعدی در حوزه هواشناسی محاسباتی ایران نقطه شروع مفیدی باشد.

- Al Shamisi, M. H., Assi, A. H., & Awad, H. A. (2011). Using artificial neural networks to forecast [١] future ambient temperature. Proceedings of the World Congress on Engineering 2011, Vol. II, London, U.K.
- Bauer, P., Thorpe, A., & Brunet, G. (2015). The quiet revolution of numerical weather prediction. [٢] Nature, 525(7567), 47-55.
- Box, G. E. P., & Jenkins, G. M. (1976). Time Series Analysis: Forecasting and Control (2nd ed.). [٣] San Francisco: Holden-Day.
- Breiman, L. (2001). Random forests. Machine Learning, 45(1), 5-32. [٤]
- Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. Proceedings of the [٥] 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining, 785-794.
- Friedman, J. H. (2001). Greedy function approximation: A gradient boosting machine. Annals of [٦] Statistics, 29(5), 1189-1232.
- Hersbach, H., et al. (2020). The ERA5 global reanalysis. Quarterly Journal of the Royal [٧] Meteorological Society, 146(730), 1999-2049.
- Hoerl, A. E., & Kennard, R. W. (1970). Ridge regression: Biased estimation for nonorthogonal [٨] problems. Technometrics, 12(1), 55-67.
- Hochreiter, S., & Schmidhuber, J. (1997). Long short-term memory. Neural Computation, 9(8), [٩] 1735-1780.
- Hyndman, R. J., & Athanasopoulos, G. (2018). Forecasting: Principles and Practice (2nd ed.). [١٠] Melbourne: OTexts.
- Kaufman, S., Rosset, S., & Perlich, C. (2011). Leakage in data mining: Formulation, detection, [١١] and avoidance. ACM Transactions on Management Information Systems, 2(3), Article 15.
- Lawrence, M. G. (2005). The relationship between relative humidity and the dewpoint [١٢] temperature in moist air: A simple conversion and applications. Bulletin of the American Meteorological Society, 86(2), 225-234.
- Lorenz, E. N. (1963). Deterministic nonperiodic flow. Journal of the Atmospheric Sciences, [١٣] 20(2), 130-141.
- McGovern, A., Elmore, K. L., Gagne, D. J., Haupt, S. E., Karstens, C. D., Lagerquist, R., Smith, [١٤] T., & Williams, J. K. (2017). Using artificial intelligence to improve real-time decision-making for high-impact weather. Bulletin of the American Meteorological Society, 98(10), 2073-2090.

- Mitchell, T. M. (1997). Machine Learning. New York: McGraw-Hill. [١٥]
- Open-Meteo. (2025). Historical Weather API Documentation. Retrieved from <https://open-meteo.com/en/docs/historical-weather-api> [١٦]
- Pedregosa, F., et al. (2011). Scikit-learn: Machine learning in Python. Journal of Machine Learning Research, 12, 2825-2830. [١٧]

پیوست: فهرست کامل ویژگی‌های تولیدشده

جدول پیوست، فهرست کامل ۴۶ ویژگی تولیدشده در ماژول feature_engineering را به همراه توضیح کوتاه هر یک نشان می‌دهد:

ستون‌های سال (year) و شماره خام روز سال (day_of_year) به ورودی مدل وارد نمی‌شوند و جای آن‌ها را بازنمایی

سینوسی/کسینوسی می‌گیرد.

جدول پیوست: فهرست کامل ویژگی‌ها و شرح هریک

ردیف	ویژگی	شرح
۱	tavg	دمای میانگین امروز (خام)
۲	tmin	دمای کمینه امروز (خام)
۳	tmax	دمای بیشینه امروز (خام)
۴	prcp	بارش امروز (خام)
۵	wspd	سرعت باد امروز (خام)
۶	pres	فشار سطح دریا امروز (خام)
۷	rhum	رطوبت نسبی امروز (خام)
۸ تا ۱۲	tavg_lag_۱ ... tavg_lag_۱۴	دمای میانگین ۱، ۲، ۳، ۷ و ۱۴ روز قبل
۱۳ تا ۲۰	tavg_roll_{3,7,14,30}_mean/std	میانگین و انحراف معیار متحرک دما (با یک روز تأخیر)
۲۱	tavg_change_1d	تغییر یک‌روزه دما
۲۲	tavg_change_3d	تغییر سه‌روزه دما
۲۳	pressure_change_1d	تغییر یک‌روزه فشار
۲۴	wind_change_1d	تغییر یک‌روزه سرعت باد
۲۵	temp_range	دامنه دمایی روز (تفاضل بیشینه و کمینه)
۲۶	temp_midpoint	نقطه میزان دما (میانگین بیشینه و کمینه)
۲۷	has_rain	پرچم بارش (بارش بیش از صفر)
۲۸	month	ماه تقویمی
۲۹ و ۳۰	doy_sin, doy_cos	بازنمایی سینوسی/کسینوسی روز سال
۳۱	temp_range_rain_interaction	تعامل دامنه دما و پرچم بارش
۳۲	is_winter	پرچم زمستان (دسامبر تا فوریه)
۳۳	is_summer	پرچم تابستان (ژوئن تا اوت)
۳۴	temp_volatility_7d	انحراف معیار متحرک ۷ روزه دما
۳۵	pressure_volatility_7d	انحراف معیار متحرک ۷ روزه فشار
۳۶	temp_trend_3d	شیب خط برازش‌شده بر ۳ روز گذشته دما
۳۷	temp_trend_7d	شیب خط برازش‌شده بر ۷ روز گذشته دما
۳۸	temp_deviation_from_30d_mean	انحراف دمای امروز از میانگین ۳۰ روزه

ردیف	ویژگی	شرح
۳۹	consecutive_rain_days	شمار روزهای بارانی هفته گذشته
۴۰	pressure_relative	فشار نسبی (علی: نسبت به میانگین ۳۶۵ روزه گذشته)
۴۱	extreme_temp_flag	پرچم دمای غیرعادی (بیش از ۲ انحراف معیار)
۴۲	rhum_lag_1	رطوبت نسبی دیروز
۴۳	rhum_roll_7_mean	میانگین متحرک ۷ روزه رطوبت
۴۴	dew_point	نقطه شبنم (فرمول Magnus–Tetens)
۴۵	temp_dewpoint_spread	فاصله دما تا نقطه شبنم
۴۶	target_next_day_tavg	متغیر هدف: دمای میانگین روز بعد